Business Intelligence

Proyecto final · Entrega 1

Diagnóstico, estrategia y diseño

Vigilancia de la contratación pública en Cundinamarca con datos del SECOP II (2023–2025)

Integrante	Código
Luis Alfredo Bañol Falla	506222712
Juan Camilo Londoño Cifuentes	507241030
Jennifer Urueña Gutiérrez	507241702

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	23/10/2026
Repositorio	https://github.com/Zierk110/bi-proyecto-equipo506222712

Resumen de la entrega

La Unidad de Analítica para el Control Fiscal de una contraloría departamental de Cundinamarca (caso verosímil construido con datos públicos reales) debe elaborar el Plan de Vigilancia y Control Fiscal 2027 y decidir qué entidades y contratos auditar con un número limitado de auditores. Hoy no puede priorizar con evidencia: cada analista descarga el SECOP II con filtros y fechas distintas, compara valores de años diferentes sin ajustarlos por inflación y cruza a mano los contratos con sus procesos de selección.

El diagnóstico ubica a la organización en la fase 3 del modelo de madurez BIMM (procesos formales de decisión basados en datos): ya existe un equipo que produce informes, pero extrae los datos directamente de la fuente, sin limpieza, sin modelo y sin data warehouse. Con un ETL en Pentaho Data Integration, un almacén en PostgreSQL, un modelo semántico y un tablero en Power BI, y un modelo predictivo en Python, el proyecto la llevará a la fase 6 (despliegue de OLAP).

Granularidad del modelo dimensional: una fila de la tabla de hechos representa un contrato electrónico firmado en el SECOP II por una entidad pública con sede en Cundinamarca, en una fecha de firma, con un proveedor, bajo una modalidad de contratación y para un objeto contractual.

1. Caso de negocio

Esta sección describe la organización cliente, la decisión que hoy no puede tomar, los síntomas de arquitectura accidental que lo impiden y las preguntas de negocio que responderá la solución de BI. El caso es verosímil y se construyó con fines académicos; los datos que lo soportan son públicos y reales.

1.1 Organización y contexto

La Unidad de Analítica para el Control Fiscal (UACF) es la dependencia técnica de una contraloría departamental que ejerce la vigilancia fiscal sobre las entidades públicas de Cundinamarca: la Gobernación y sus entidades descentralizadas, las alcaldías, los hospitales públicos y los institutos municipales. Pertenece al sector público de control fiscal y la conforman 11 personas (una coordinadora, ocho analistas y dos ingenieros de datos) que apoyan a cerca de 40 auditores. Opera desde la sede principal en Bogotá.

La decisora es la Contralora Auxiliar de Planeación, responsable de proponer al despacho del Contralor el Plan de Vigilancia y Control Fiscal (PVCF) de cada año. Para 2027 debe seleccionar qué entidades y qué contratos se auditan, y justificar la selección con indicadores de riesgo comparables: valor contratado en pesos constantes, peso de la contratación directa, tiempos entre la publicación del proceso y la firma, y concentración del valor en pocos proveedores.

Hoy la Contralora no puede tomar esa decisión con evidencia confiable. La UACF ya produce informes con datos del SECOP II para sustentar el plan, pero cada analista la descarga con filtros y fechas de corte distintas, suma valores de 2023 y de 2025 como si tuvieran el mismo poder adquisitivo y cruza a mano los contratos con sus procesos en hojas de cálculo. En consecuencia, las cifras que llegan al comité no coinciden entre sí y la selección de auditorías termina apoyándose en denuncias puntuales y en la experiencia de cada auditor, y no en un análisis sistemático del riesgo.

1.2 Síntomas de arquitectura accidental

#	Síntoma	Evidencia en el caso	Capa afectada
S1	Cifras distintas del mismo indicador según quién elabore el informe	El SECOP II se actualiza a diario y cada analista lo descarga en fechas y con filtros distintos (por departamento, por ciudad o por entidad); sin fecha de corte documentada, dos informes del mismo trimestre no coinciden.	Fuentes / Gobierno y metadatos
S2	Valores de distintos años comparados en pesos corrientes	Los informes suman y comparan contratos de 2023 y de 2025 sin deflactar, lo que infla artificialmente el crecimiento de la contratación.	Integración (ETL) / Almacén de datos
S3	Cruce manual entre contratos y procesos de selección	Los contratos y los procesos se descargan por separado y se cruzan con BUSCARV por el código del proceso (por ejemplo, CO1.BDOS.834401); con decenas de miles de filas el cruce falla o se abandona.	Integración (ETL)

#	Síntoma	Evidencia en el caso	Capa afectada
S4	Datos personales de contratistas en archivos sin control	Los archivos descargados incluyen nombre y cédula de contratistas personas naturales y circulan por correo entre analistas, sin roles de acceso ni anonimización.	Gobierno, metadatos, monitoreo y seguridad
S5	Reportes estáticos y sin histórico consultable	El comité de planeación recibe tablas de Excel pegadas en presentaciones; una consulta puntual (por ejemplo, contratación directa de un hospital por trimestre) tarda más de una semana.	Usuario final

1.3 Preguntas de negocio

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
P0	¿Qué entidades de Cundinamarca concentran el mayor valor contratado por contratación directa entre 2023 y 2025, en pesos constantes, y cómo evolucionó su participación por trimestre?	BI	Describe y compara lo ocurrido con datos históricos estructurados, mediante agregaciones por entidad, modalidad y periodo.
P1	¿Cuántos días transcurren en promedio entre la publicación del proceso y la firma del contrato, por modalidad y por entidad?	BI	Mide el desempeño histórico del proceso de compra integrando contratos y procesos.
P2	¿Qué proveedores concentran el valor contratado en cada entidad y qué participación tienen los diez principales?	BI	Es un análisis descriptivo de concentración sobre contratos ya firmados.
P3	¿Qué segmentos de bienes y servicios (código UNSPSC) concentran el valor contratado y cómo cambió su participación año a año?	BI	Segmenta hechos pasados por la jerarquía del objeto contractual, sin inferir causas.
P4	¿Cuánto valor contratará cada entidad por mes en 2026 y cuáles superarán su promedio 2023–2025?	BA	Es predictiva: aplica un modelo estadístico a la serie histórica para estimar valores futuros.

2. Inventario de fuentes

Se integran tres fuentes públicas de dos publicadores (Colombia Compra Eficiente y DANE) en tres formatos distintos: CSV, JSON y XLSX. F1 alimenta la tabla de hechos, F2 aporta las fechas y características de los procesos de selección que dieron origen a cada contrato, y F3 permite expresar los valores en pesos constantes. No se usan datos sintéticos, y los documentos de identidad de personas naturales se reemplazan por un código anónimo durante el ETL.

F1 – SECOP II, Contratos Electrónicos (Colombia Compra Eficiente). Conjunto publicado en el Portal Nacional de Datos Abiertos desde 2019, con actualización diaria y 95 columnas. Cada fila es un contrato registrado en el SECOP II, con la entidad, el proveedor, la modalidad, las fechas, el código UNSPSC y los valores. Se extrae por la API SODA en formato CSV, filtrando las entidades de Cundinamarca con fecha de firma entre el 1 de enero de 2023 y el 31 de diciembre de 2025.

F2 – SECOP II, Procesos de Contratación (Colombia Compra Eficiente). Registra los procesos de compra publicados en el SECOP II, se adjudiquen o no; la descarga trae 57 columnas. Se extrae como JSON por la API SODA, consultando solo los procesos que corresponden a los contratos de F1 mediante el campo id_del_portafolio, que equivale al campo proceso_de_compra de F1. De los 137.016 contratos de F1, 137.001 encuentran su proceso en F2.

F3 – Índice de Precios al Consumidor, IPC (DANE). Anexo en Excel del boletín del IPC de septiembre de 2026 (publicado el 07/10/2026). De sus 18 hojas se usa la hoja 13, con el índice mensual del IPC de servicios (base diciembre de 2018 = 100) entre enero de 2009 y septiembre de 2026. Se elige este índice porque 110.254 de los 137.016 contratos (80 %) son de prestación de servicios, y porque el anexo no publica la serie mensual del IPC total. Con él se convierte el valor de cada contrato a pesos constantes de diciembre de 2025, según el mes de su firma.

La tabla de hechos tendrá 137.016 registros, uno por contrato de F1 dentro del alcance, lo que supera el mínimo de 50.000 y cubre tres años de historia. Los conteos, la fecha de descarga y las muestras de 20 filas por fuente se generaron con los scripts del repositorio (datos/descargar_fuentes.py y datos/perfilar.py).

2.1 Fuentes

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
F1	https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Contratos-Electr-nicos/jbjy-vk9h	CSV (API SODA)	137.016	01/01/2023 – 31/12/2025	23/10/2026	CC BY-SA (Atribución-CompartirIgual)
F2	https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Procesos-de-Contrataci-n/p6dx-8zbt	JSON (API SODA)	148.228	Procesos de los contratos de F1 (publicados desde 2020)	23/10/2026	CC BY-SA (Atribución-CompartirIgual)
F3	https://www.dane.gov.co/index.php/estadisticas-por-tema/precios-y-costos/indice-de-precios-al-consumidor-ipc/ipc-informacion-tecnica	XLSX	36 meses (de 213 en la hoja 13)	01/2023 – 12/2025	23/10/2026	Uso libre con atribución al DANE

2.2 Problemas de calidad detectados

Fuente	Campo	Problema	Ejemplo real del dato
F1	fecha_de_firma	La fecha llega como texto con hora y milisegundos en formato ISO; en la exportación del portal el mismo campo sale como MM/DD/AAAA, distinto al formato colombiano.	«2025-04-21T00:00:00.000»
F1	codigo_de_categoria_principal	El código UNSPSC trae un prefijo de versión que impide derivar directamente segmento, familia y clase.	«V1.85101500»

Fuente	Campo	Problema	Ejemplo real del dato
F1	estado_contrato / sector	Mayúsculas y minúsculas inconsistentes dentro del mismo catálogo.	«terminado» y «cedido» frente a «Cerrado»; sector «deportes»
F1	ciudad	Valor no informado codificado como texto en lugar de nulo (12.586 contratos).	«No Definido»
F1	tipodocproveedor / documento_proveedor	112.901 de 137.016 contratos son con personas naturales identificadas con cédula: dato personal que debe anonimizarse.	«Cédula de Ciudadanía» (número omitido)
F1	tipo_de_documento_ordenador_del_gasto	Catálogo con valores en dos idiomas para el mismo concepto.	«Citizenship Identification» frente a «Cédula de Ciudadanía»
F2	Registro completo	8.348 filas duplicadas exactas, porque un mismo proceso se repite en la respuesta de la API.	8.348 duplicados en 148.228 filas
F2	fecha_de_publicacion_del / fase	Hay procesos publicados años antes del alcance y valores de fase en inglés; los días entre publicación y firma pueden salir atípicos.	«2020-07-15T00:00:00.000»; fase «Clarification submission»
F2	departamento_entidad	Procesos ligados a contratos de Cundinamarca registran otro departamento para la entidad (796 filas).	«Distrito Capital de Bogotá»
F3	Estructura del libro	Libro de 18 hojas; la serie está en la hoja 13 tras siete filas de títulos, con encabezado en dos filas, mes escrito como texto y notas al pie. La hoja del IPC total solo trae septiembre de cada año, por lo que no sirve como serie mensual.	2023 · «Enero» · 117.93; nota al pie «Fuente: DANE.»

Los diccionarios completos están en el Anexo A y en /datos/diccionarios; la muestra de 20 filas por fuente está en /datos/muestras del repositorio.

3. Diagnóstico de madurez

El diagnóstico usa el modelo de madurez de BI (BIMM) de siete fases visto en clase: 1. No existe BI; 2. Datos accesibles sin BI; 3. Procesos formales de decisión basados en datos; 4. Data warehouse; 5. Crecimiento del DW y reporting formal; 6. Despliegue de OLAP; 7. BI formalizado (Fundación Universitaria Konrad Lorenz, 2026).

Elemento	Respuesta
Fase actual	Fase 3. Procesos formales de toma de decisiones basada en datos
Evidencia	Existe un equipo (la UACF) que controla los datos y produce informes para sustentar el PVCF, lo que corresponde a la fase 3. Sin embargo, los datos se extraen directamente de la fuente sin limpieza ni modelado: el conjunto de contratos del SECOP II tiene más de 5,6 millones de filas, la API entrega 1.000 filas por defecto y traer solo los procesos de Cundinamarca exigió cerca de 900 consultas sucesivas. Persisten las señales de falta de estrategia de BI: cifras contradictorias (S1, S2), dependencia de hojas de cálculo (S3, S5) y ausencia de un responsable del dato (S4).
Por qué no es la fase siguiente	No está en la fase 4 porque no existe un data warehouse ni ningún repositorio integrado: cada informe vuelve a descargar y cruzar los datos desde el SECOP II, el costo de esa extracción repetida no se ha resuelto y el reporting sigue siendo personal, en archivos de cada analista.
Fase objetivo al final del proyecto	Fase 6. Despliegue de OLAP
Brechas que cierra el proyecto	Extracción repetida y manual desde la fuente → ETL programado en Pentaho Data Integration con staging (capa 2). Sin integración automática de contratos y procesos → cruce por id_del_portafolio en el ETL (capa 2). Valores en pesos corrientes → cálculo del valor constante con el IPC en el ETL (capa 2). Sin histórico único → almacén PostgreSQL en estrella (capa 3). Indicadores calculados a mano → medidas DAX únicas en el modelo semántico (capa 3). Sin análisis multidimensional → cubo tabular con jerarquías de tiempo, entidad y objeto contractual (capa 3). Reportes estáticos → tablero en Power BI Service (capa 4). Sin capacidad de anticipación → modelo predictivo en Python (capa 4). Datos personales sin control y sin trazabilidad → anonimización, roles, descarga.md y etl_log (capa 5).

El salto de la fase 3 a la 6 es posible porque el proyecto entrega, en orden, los componentes de cada fase siguiente: construye el almacén con el histórico 2023–2025 integrado y limpio, que elimina las descargas repetidas desde el SECOP II (fase 4), publica un tablero con reglas de cálculo únicas que reemplaza los informes manuales (fase 5) y habilita el análisis multidimensional sobre el cubo tabular de Power BI (fase 6).

La fase 7 (BI formalizado) queda fuera del alcance. Aunque el proyecto incluye un modelo predictivo como piloto, esa fase exige procesos de calidad de datos y de inteligencia de negocio en toda la organización, una cultura que distinga los sistemas transaccionales de los de apoyo a la decisión, y un gobierno de datos con responsables formales y patrocinio del despacho, decisiones que no dependen del equipo consultor.

4. Arquitectura

La arquitectura propuesta sigue el modelo de cinco capas visto en clase: fuentes, integración, almacén, usuario final y una capa transversal de gobierno, metadatos, monitoreo y seguridad. Los datos fluyen en lotes mensuales desde las tres fuentes públicas hacia un área de staging, se transforman con Pentaho, se cargan en un almacén dimensional en PostgreSQL y se consumen desde Power BI y desde un notebook de Python.

4.1 Diagrama de cinco capas del caso

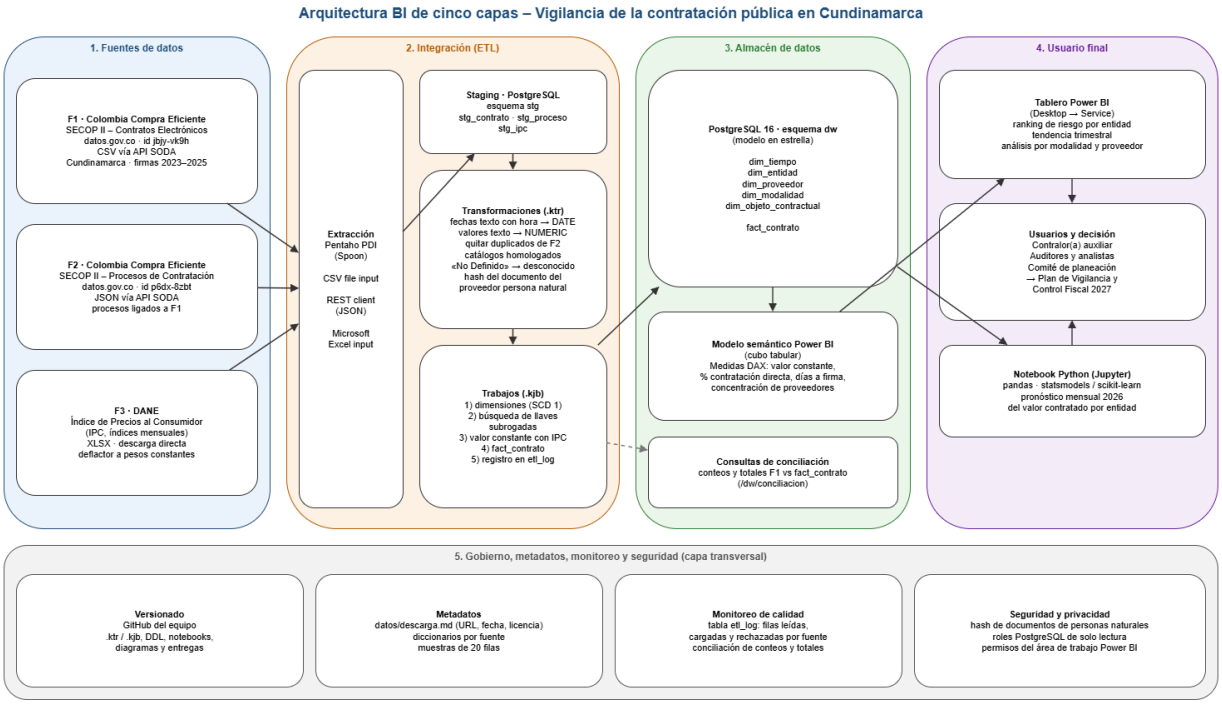


Ilustración 1. Arquitectura de cinco capas del caso. Fuente: elaboración propia. Archivos PNG y draw.io en /docs/diagramas.

4.2 Componentes por capa

Capa	Componentes y herramientas del caso	Función en el caso
1. Fuentes de datos	F1 SECOP II – Contratos Electrónicos (CSV, API SODA); F2 SECOP II – Procesos de Contratación (JSON, API SODA); F3 DANE – IPC (XLSX)	Proveer los contratos (hechos), los datos del proceso de selección de cada contrato y el índice para expresar los valores en pesos constantes.
2. Integración (ETL)	Pentaho Data Integration (Spoon): pasos CSV file input, REST client y Microsoft Excel input; staging en PostgreSQL (esquema stg); transformaciones .ktr y trabajos .kjb	Extraer, limpiar (fechas, códigos UNSPSC, valores «No Definido»), cruzar contratos con procesos, anonimizar documentos de personas naturales, deflactar y cargar dimensiones y hechos con llaves subrogadas.
3. Almacén de datos	PostgreSQL 16 (esquema dw) administrado con DBeaver; modelo en estrella con fact_contrato y cinco dimensiones; modelo semántico tabular de Power BI	Conservar el histórico 2023–2025 integrado y exponer indicadores consistentes para el análisis multidimensional.

Capa	Componentes y herramientas del caso	Función en el caso
4. Usuario final	Power BI Desktop y Power BI Service; Jupyter Notebook con pandas y statsmodels o scikit-learn	Responder P0 a P3 con tableros interactivos y P4 con el pronóstico 2026; consulta para la Contralora Auxiliar y el comité de planeación.
5. Gobierno, metadatos, monitoreo y seguridad	GitHub (versionado), datos/descarga.md, diccionarios por fuente, tabla etl_log, consultas de conciliación, hash SHA-256 de documentos de personas naturales, roles de PostgreSQL y permisos del área de trabajo de Power BI	Garantizar trazabilidad de cada cifra, calidad verificable en cada carga, protección de datos personales y control de acceso.

4.3 Marco de Referencia de cuatro categorías

Categoría	Decisión tomada	Justificación
Arquitectura de información	Indicadores: valor contratado en pesos constantes, porcentaje de contratación directa, días entre publicación y firma, participación de los principales proveedores y por segmento UNSPSC, a nivel de contrato para 2023–2025. Usuarios: Contralora Auxiliar, analistas y comité de planeación.	Las preguntas P0 a P4 exigen comparar entidades y años en una misma unidad de valor y ver tendencias; el grano de contrato permite cualquier agregación y construir la serie del pronóstico.
Arquitectura de datos	Staging más almacén dimensional en estrella (Kimball) con fact_contrato y cinco dimensiones; SCD tipo 1; miembro «No definido» para valores no informados; dimensión de proveedor anonimizada.	Las fuentes son heterogéneas; la estrella simplifica las consultas y el modelo de Power BI, y la anonimización en la dimensión protege los datos personales sin perder el análisis de concentración.
Arquitectura técnica	Pentaho Data Integration, PostgreSQL 16, Python 3 y GitHub; ejecución por lotes mensual.	Son herramientas vistas en el curso y de licencia libre; el volumen (decenas o cientos de miles de contratos) no requiere tecnologías Big Data, y la carga mensual basta para la planeación anual.
Arquitectura de producto	Power BI Desktop y Service para tableros y cubo tabular; Jupyter Notebook para el modelo predictivo.	Power BI es la herramienta del curso, soporta DAX, jerarquías y publicación web; Python ofrece librerías maduras de pronóstico.

4.4 Decisión de despliegue

Criterio	On-premise	Opción cloud: PaaS + SaaS (Azure Database for PostgreSQL + Power BI Service)	Elegida y por qué
Costo	Sin pago recurrente por software de base (PostgreSQL y Pentaho son libres); usa el servidor existente, pero exige mantenimiento y copias de respaldo internas.	Pago mensual por cómputo y almacenamiento de la base PaaS, más licencias Power BI Pro por usuario; no requiere inversión en hardware.	Híbrida: ETL y almacén on-premise, consumo en Power BI Service (SaaS). Solo se pagan las licencias de quienes publican y consultan.

Criterio	On-premise	Opción cloud: PaaS + SaaS (Azure Database for PostgreSQL + Power BI Service)	Elegida y por qué
Seguridad y cumplimiento	Control total sobre los datos, pero la entidad debe gestionar parches, accesos y respaldos.	Cifrado y certificaciones del proveedor; los datos salen de la red de la entidad.	Los datos personales se anonimizan en el ETL dentro de la red interna, de modo que a la nube solo llega el modelo agregado y sin datos de personas, en línea con la Ley 1581 de 2012.
Escalabilidad	Limitada al hardware disponible; suficiente para cientos de miles de filas.	Elástica según demanda.	Tres años de contratos de un departamento caben holgadamente en un servidor; si se amplía a todo el país, la base puede migrar a PaaS sin cambiar el modelo.
Acceso móvil	Requiere VPN o publicar un servidor de reportes propio.	Nativo mediante la aplicación móvil de Power BI.	Los auditores en campo consultan el tablero desde el celular, lo que se resuelve con Power BI Service.

Opción elegida: despliegue híbrido. El procesamiento (Pentaho) y el almacén (PostgreSQL) quedan on-premise, y la capa de consumo se publica en Power BI Service (SaaS) mediante una puerta de enlace de datos local. Así se combina el control de los datos personales y el bajo costo de la operación interna con el acceso web y móvil que necesitan los auditores.

5. Modelo dimensional

Se adopta un modelo dimensional en estrella según la metodología de Kimball y Ross (2013), con una tabla de hechos, fact_contrato, rodeada de cinco dimensiones desnormalizadas: tiempo, entidad, proveedor, modalidad y objeto contractual. Los identificadores del contrato, del proceso y el estado se conservan en la tabla de hechos como dimensiones degeneradas.

5.1 Proceso de negocio

El proceso de negocio modelado es la contratación pública de las entidades de Cundinamarca. Una entidad publica un proceso de compra en el SECOP II bajo una modalidad de selección; cuando lo adjudica, firma un contrato electrónico con un proveedor por un valor, un plazo y un objeto clasificado con el código UNSPSC. La contraloría vigila ese proceso: para planear sus auditorías necesita medir cuánto, cómo, con quién y en qué contrata cada entidad, y cómo cambia en el tiempo.

5.2 Granularidad

Una fila de la tabla de hechos representa un contrato electrónico firmado en el SECOP II por una entidad pública con sede en Cundinamarca, en una fecha de firma, con un proveedor, bajo una modalidad de contratación y para un objeto contractual.

5.3 Métricas de la tabla de hechos

Métrica	Tipo de dato	Aditividad	Origen o fórmula
valor_contrato	NUMERIC(18,2)	Aditiva	F1.valor_del_contrato (texto convertido a número)
valor_contrato_constante	NUMERIC(18,2)	Aditiva	valor_contrato × 144,87 (IPC de servicios dic-2025) / IPC de servicios del mes de firma (F3)
valor_pagado	NUMERIC(18,2)	Aditiva (corte a la fecha de descarga)	F1.valor_pagado
duracion_dias	INTEGER	No aditiva (se promedia)	fecha_de_fin_del_contrato − fecha_de_inicio_del_contrato (F1)
dias_publicacion_a_firma	INTEGER	No aditiva (se promedia)	F1.fecha_de_firma − F2.fecha_de_publicacion_del
conteo_contratos	SMALLINT	Aditiva	1 por contrato
pct_contratacion_directa	DECIMAL(5,2)	No aditiva	valor constante de modalidades directas / valor constante total × 100 (medida DAX)

5.4 Dimensiones

Dimensión	Atributos principales	Jerarquía	Fuente
Tiempo	fecha, día, nombre del día, mes, trimestre, año, índice IPC del mes	día → mes → trimestre → año	Generada (calendario 2023–2025) y F3
Entidad	NIT, nombre, orden, sector, rama, centralizada, ciudad, departamento	ciudad → departamento; sector → orden	F1
Proveedor	código anónimo (hash), nombre solo de personas jurídicas, tipo de documento, tipo de persona, es pyme, es grupo	tipo de persona → proveedor	F1 (anonimizado en el ETL)
Modalidad	justificación, modalidad de contratación, tipo de selección (competitiva o no competitiva)	justificación → modalidad → tipo de selección	F1 y F2
Objeto contractual	código UNSPSC, clase, familia, segmento, tipo de contrato	clase → familia → segmento	F1 (código de categoría principal)

5.5 Diagrama del esquema

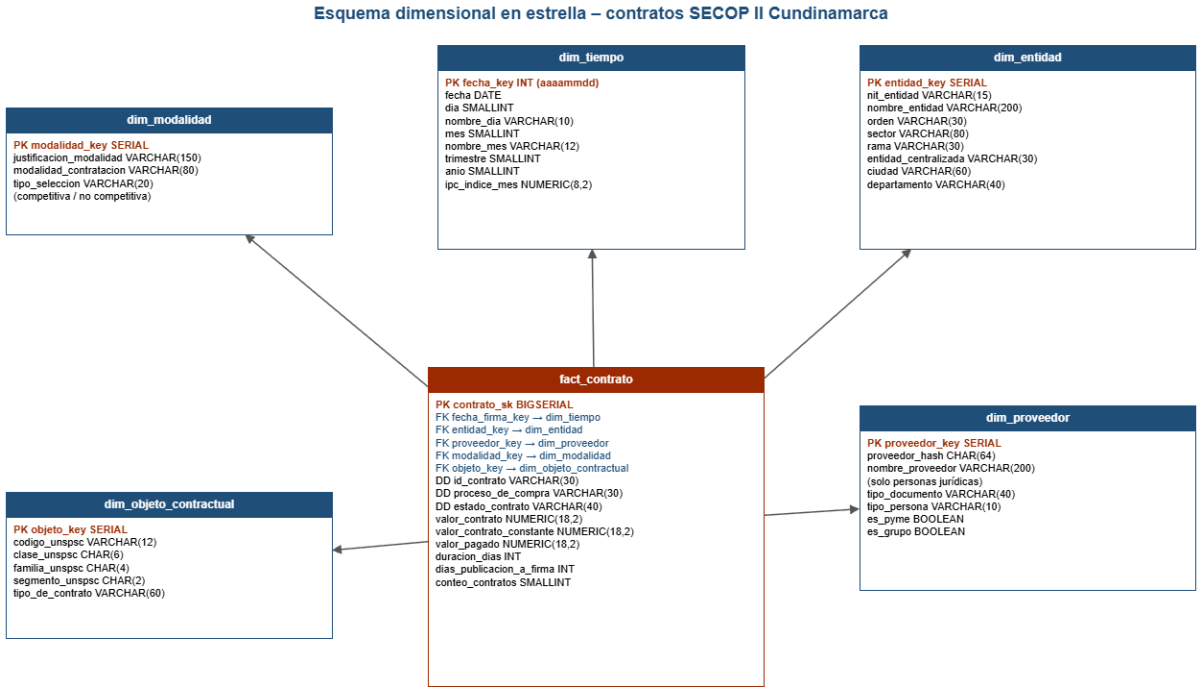


Ilustración 2. Esquema dimensional en estrella con llaves primarias y foráneas. Fuente: elaboración propia. Archivos PNG y draw.io en /docs/diagramas.

Se eligió un esquema en estrella y no un copo de nieve porque las dimensiones son de tamaño moderado y sus jerarquías (ciudad y departamento, segmento y familia UNSPSC, modalidad y tipo de selección) caben en una sola tabla con una redundancia mínima. La estrella reduce las uniones, mejora el rendimiento del modelo tabular de Power BI, que está optimizado para relaciones de uno a muchos entre dimensiones y hechos, y hace el modelo más fácil de entender para los analistas. Normalizar la jerarquía UNSPSC en tablas separadas no aportaría beneficios, porque se carga una sola vez y casi no cambia.

5.6 Trazabilidad con las preguntas

Pregunta	Métricas que usa	Dimensiones que usa
P0	valor_contrato_constante, pct_contratacion_directa, conteo_contratos	Entidad, Modalidad (tipo de selección), Tiempo (trimestre, año)
P1	dias_publicacion_a_firma, conteo_contratos	Modalidad, Entidad, Tiempo (año)
P2	valor_contrato_constante, conteo_contratos	Proveedor, Entidad, Tiempo (año)
P3	valor_contrato_constante, conteo_contratos	Objeto contractual (segmento, familia), Tiempo (año)
P4	valor_contrato_constante agregado como serie mensual 2023–2025, insumo del pronóstico en Python	Tiempo (mes), Entidad

6. Referencias

Agencia Nacional de Contratación Pública – Colombia Compra Eficiente. (2026a). SECOP II – Contratos electrónicos [Conjunto de datos]. Portal Nacional de Datos Abiertos. https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Contratos-Electr-nicos/jbjy-vk9h

Agencia Nacional de Contratación Pública – Colombia Compra Eficiente. (2026b). SECOP II – Procesos de contratación [Conjunto de datos]. Portal Nacional de Datos Abiertos. https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Procesos-de-Contrataci-n/p6dx-8zbt

Congreso de la República de Colombia. (2012, 17 de octubre). Ley 1581 de 2012: Por la cual se dictan disposiciones generales para la protección de datos personales. Diario Oficial No. 48.587. http://www.secretariasenado.gov.co/senado/basedoc/ley_1581_2012.html

Departamento Administrativo Nacional de Estadística [DANE]. (2026, 7 de octubre). Índice de Precios al Consumidor (IPC): anexos, septiembre de 2026 [Conjunto de datos]. https://www.dane.gov.co/index.php/estadisticas-por-tema/precios-y-costos/indice-de-precios-al-consumidor-ipc/ipc-informacion-tecnica

Fundación Universitaria Konrad Lorenz. (2026). Modelo de madurez de inteligencia de negocios (BIMM) [Material de clase, curso Business Intelligence]. https://virtual.konradlorenz.edu.co/course/section.php?id=107056

Kimball, R., & Ross, M. (2013). The data warehouse toolkit: The definitive guide to dimensional modeling (3.ª ed.). Wiley.

Anexos

Anexo A. Diccionarios de datos

F1 – SECOP II, Contratos Electrónicos (jbjy-vk9h), CSV – campos usados de 95

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
nombre_entidad	Texto	Entidad que publica el contrato	ESE HOSPITAL SAN JOSE DE GUADUAS	Mayúsculas y sin tildes
nit_entidad	Número	NIT de la entidad	860020283	Sin dígito de verificación
departamento	Texto	Departamento de la entidad	Cundinamarca	Filtro del alcance
ciudad	Texto	Ciudad de la entidad	Guaduas	12.586 «No Definido»
orden	Texto	Orden de la entidad	Territorial	—
sector	Texto	Sector de la entidad	Servicio Público	Minúsculas en «deportes»
proceso_de_compra	Texto	Código del proceso de origen	CO1.BDOS.7993212	Llave de cruce con F2
estado_contrato	Texto	Estado del contrato	En ejecución	«terminado», «cedido»
codigo_de_categoria_principal	Texto	Código UNSPSC del objeto	V1.85101500	Prefijo «V1.»
tipo_de_contrato	Texto	Tipo de contrato	Prestación de servicios	—
modalidad_de_contratacion	Texto	Modalidad de selección	Contratación directa	Variantes «(con ofertas)»
fecha_de_firma	Texto (fecha)	Fecha de firma	2025-04-21T00:00:00.000	Texto con hora
fecha_de_inicio_del_contrato	Texto (fecha)	Inicio del contrato	AAAA-MM-DDT00:00:00.000	1.199 nulos
fecha_de_fin_del_contrato	Texto (fecha)	Fin del contrato	AAAA-MM-DDT00:00:00.000	Texto con hora
tipodocproveedor	Texto	Tipo de documento del proveedor	Cédula de Ciudadanía	124 «No Definido»
documento_proveedor	Texto	Documento del proveedor	(omitido por privacidad)	Dato personal: se anonimiza
proveedor_adjudicado	Texto	Nombre del proveedor	(omitido por privacidad)	Dato personal en personas naturales
es_pyme	Texto	Indicador de pyme	No	Texto Sí/No, no booleano
valor_del_contrato	Número	Valor del contrato en pesos	45000000	Pesos corrientes
valor_pagado	Número	Valor pagado a la fecha	0	Cambia con cada descarga

F2 – SECOP II, Procesos de Contratación (p6dx-8zbt), JSON – campos usados de 57

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
entidad	Texto	Entidad que publica el proceso	ESTABLECIMIENTO PENITENCIARIO DE MEDIANA SEGURIDAD Y CARCELARIO DE GACHETA	Grafía distinta a F1
nit_entidad	Texto	NIT de la entidad	832001803	Texto en F2 y número en F1
departamento_entidad	Texto	Departamento de la entidad	Cundinamarca	796 «Distrito Capital de Bogotá»
ordenentidad	Texto	Orden de la entidad	Territorial	—
ppi	Texto	Código de unidad de contratación (PCI)	701878258	—
id_del_portafolio	Texto	Identificador del proceso	CO1.BDOS.1339442	Llave de cruce con F1
fase	Texto	Fase del proceso	Presentación de oferta	Valores en inglés; 55 nulos
fecha_de_publicacion_del	Texto (fecha)	Primera publicación del proceso	2020-07-15T00:00:00.000	Fechas fuera del alcance; 65 nulos
modalidad_de_contratacion	Texto	Modalidad de selección	Contratación directa	—
conteo_de_respuestas_a_ofertas	Texto (número)	Ofertas recibidas	0	Número como texto

F3 – DANE, Índice de Precios al Consumidor (anexo sep. 2026, hoja 13: IPC de servicios), XLSX

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
Año	Número	Año del índice	2025	Filas de título y notas al pie
Mes	Texto	Mes del índice	Diciembre	Nombre del mes, no número
Índice	Número	IPC de servicios (base dic. 2018 = 100)	144.87	Encabezado en dos filas
Variación mensual	Número	Variación porcentual frente al mes anterior	0.56	Subencabezado bajo «Variación»
Variación anual	Número	Variación porcentual a doce meses	6.42	Subencabezado bajo «Variación»

Anexo B. Diagramas a tamaño completo

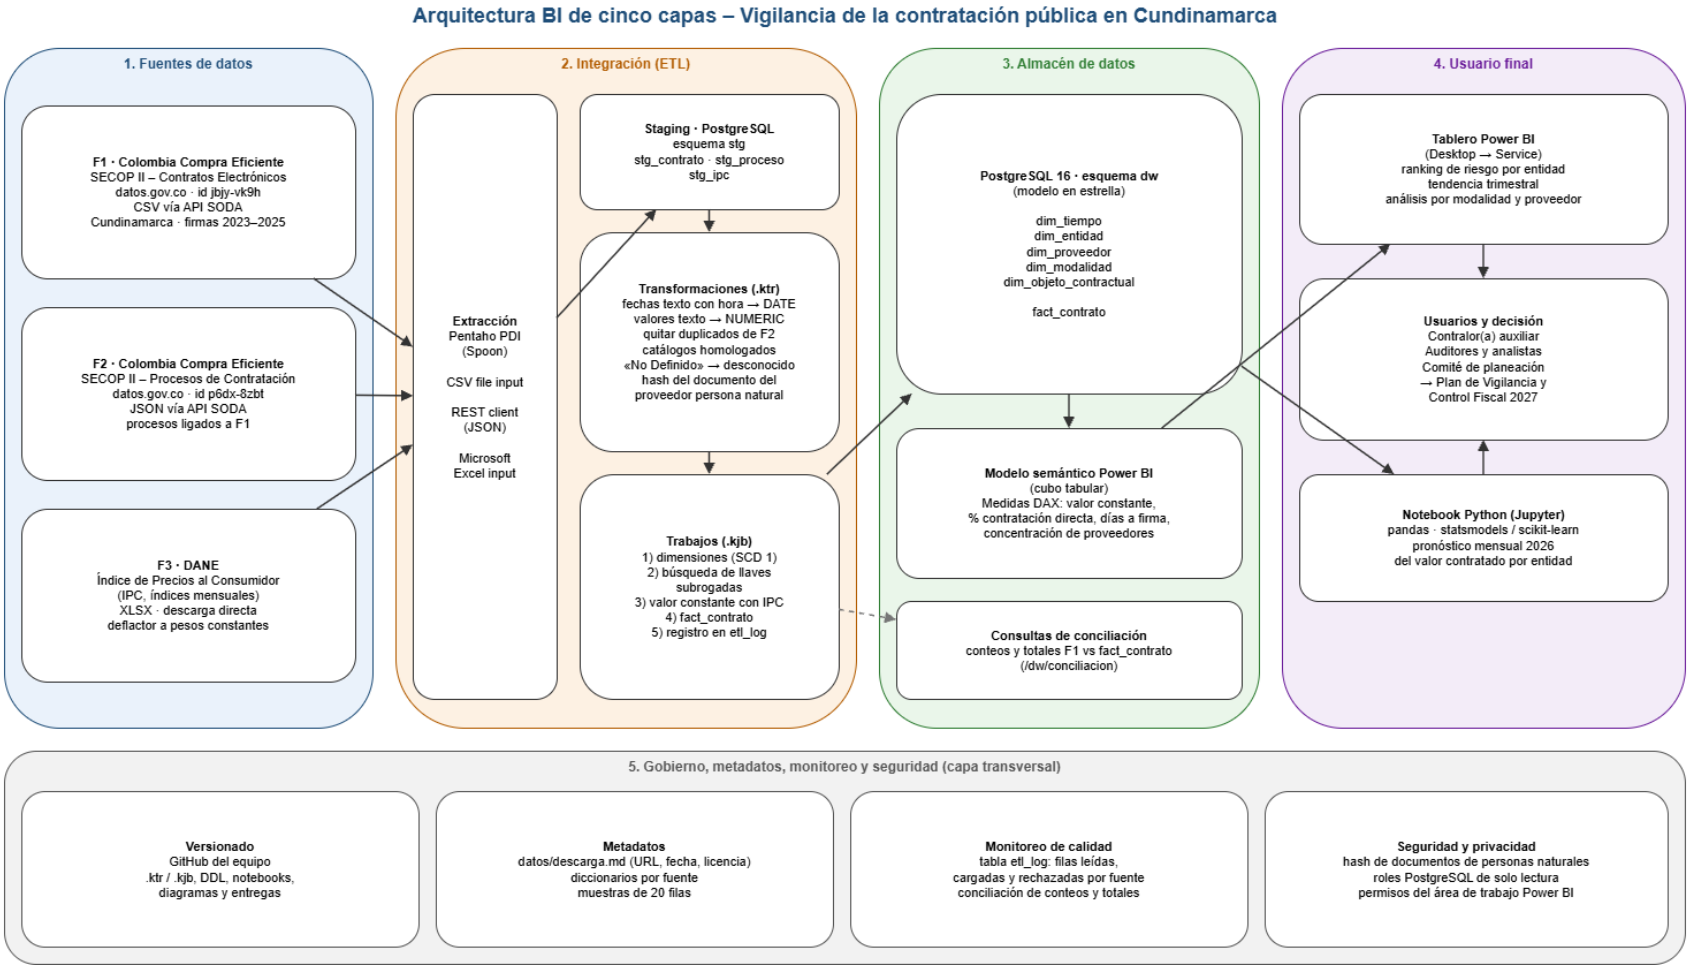


Ilustración 3. Arquitectura de cinco capas (tamaño completo). Fuente: elaboración propia.

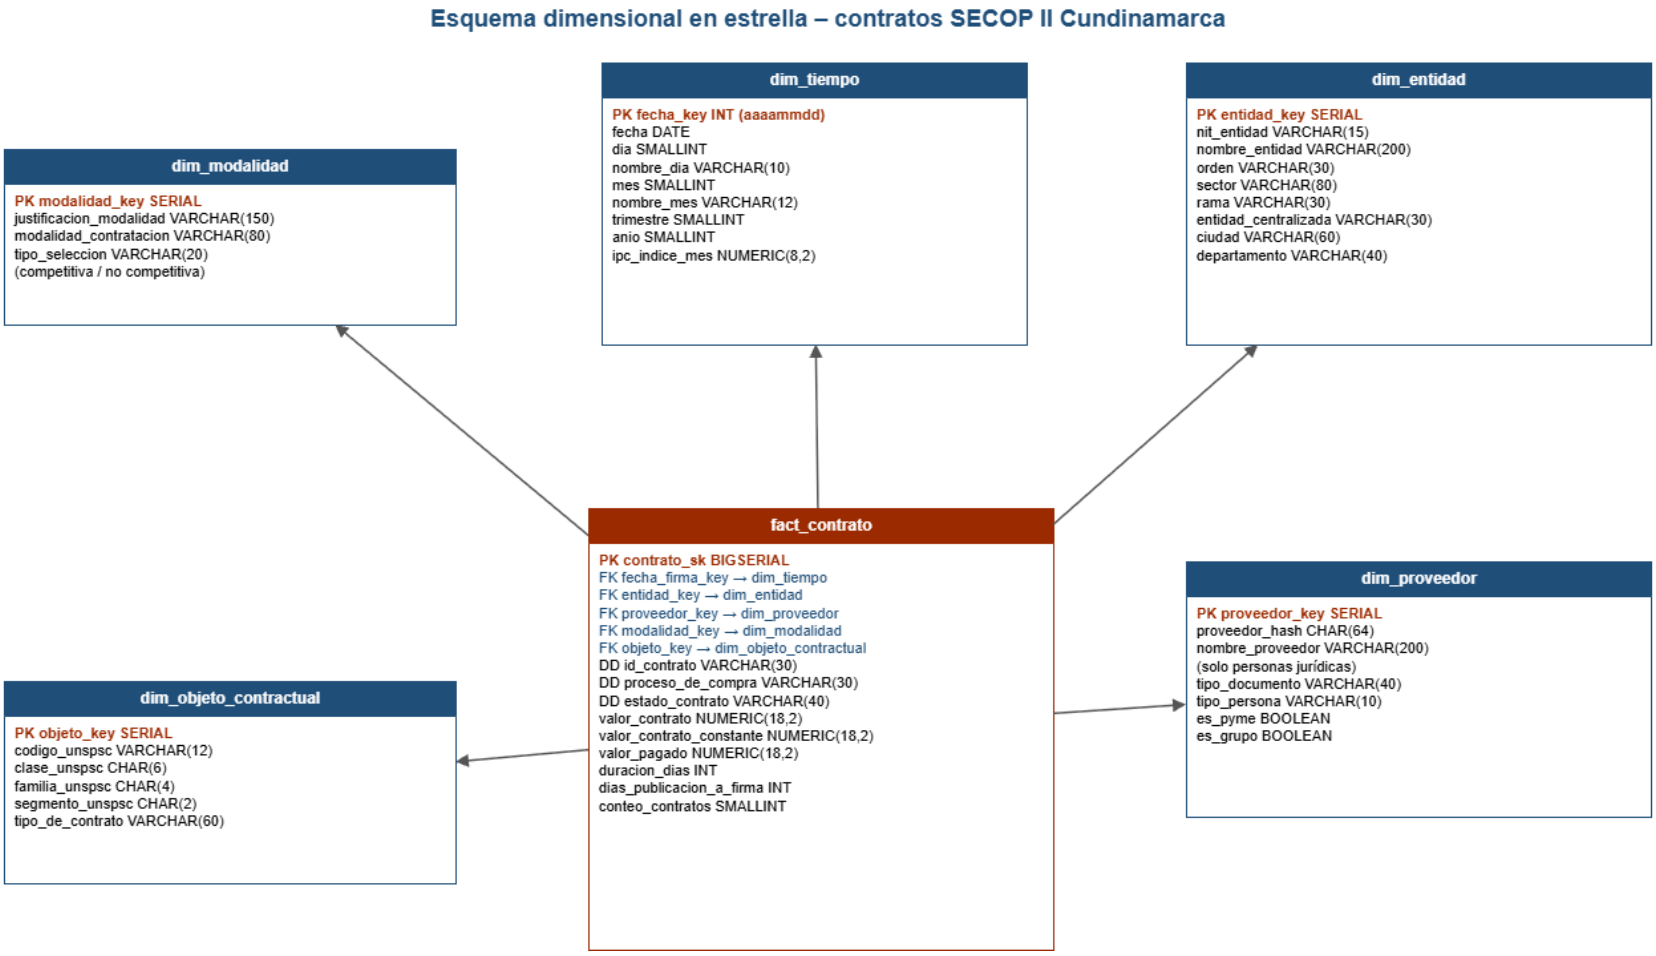


Ilustración 4. Esquema dimensional en estrella (tamaño completo). Fuente: elaboración propia.