Business Intelligence

Proyecto final · Entrega 2

Data warehouse, ETL y tablero

Vigilancia de la contratación pública en Cundinamarca con datos del SECOP II (2023–2025)

Integrante	Código
Luis Alfredo Bañol Falla	506222712
Juan Camilo Londoño Cifuentes	507241030
Jennifer Urueña Gutiérrez	507241702

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	09/11/2026
Repositorio	https://github.com/Zierk110/bi-proyecto-equipo506222712
Motor de base de datos	MySQL 8.4 (Community Server 8.4.13 LTS)
Herramienta del tablero	Power BI Desktop

Resumen de la entrega

Se construyó un data warehouse en MySQL 8.4 con un modelo en estrella de seis tablas: cinco dimensiones (tiempo, entidad, proveedor, modalidad y objeto contractual) y la tabla de hechos fact_contrato, que quedó con 137.016 contratos firmados por entidades de Cundinamarca entre 2023 y 2025. La carga se ejecuta con un solo trabajo de Pentaho Data Integration (j_carga_completa.kjb) que corre seis transformaciones a partir de las tres fuentes originales (CSV, JSON y XLSX) y aplica las reglas de limpieza diagnosticadas en la Entrega 1. La conciliación cuadra registro a registro y en el total del valor contratado, y el tablero de Power BI se conecta directamente a la base de datos.

Respuesta a la pregunta principal (P0): el 60,52 % del valor contratado en el periodo, en pesos constantes de diciembre de 2025, se adjudicó por modalidades no competitivas. La entidad que concentra el mayor valor de contratación directa es el Departamento de Cundinamarca – Secretaría de Hacienda, con $1.242,5 mil millones, seguida del Municipio de Soacha con $1.059,8 mil millones. Por trimestre, la participación de la contratación directa alcanza su máximo en el primer trimestre de cada año (68,2 % en 2023, 78,5 % en 2024 y 84,7 % en 2025) y su mínimo en 2023-T2 (29,6 %).

1. Modelo físico

1.1 Motor y base de datos

Motor: MySQL Community Server 8.4.13 LTS, instalado localmente como servicio de Windows. Base de datos: bi_secop, con codificación utf8mb4 (collation utf8mb4_0900_ai_ci). Se usa un único esquema (bi_secop): no se creó una capa de staging en la base de datos, porque las transformaciones de PDI leen las fuentes originales y aplican la limpieza en memoria antes de escribir en las tablas del data warehouse.

Se eligió MySQL, en lugar de PostgreSQL previsto en la Entrega 1, por recomendación del enunciado de esta entrega. El cambio no afecta el modelo: las tablas, llaves y métricas son las mismas del diseño. La carga usa el usuario bi_etl, con permisos solo sobre bi_secop; la contraseña se define en el archivo kettle.properties de cada integrante y no está en el repositorio.

1.2 Tablas creadas

Las llaves de las dimensiones son subrogadas (AUTO_INCREMENT, generadas en la carga), salvo fecha_key, que es inteligente (aaaammdd). La llave de la fuente se conserva como atributo: nit_entidad en dim_entidad, proveedor_hash en dim_proveedor (SHA-256 del documento), modalidad y justificación en dim_modalidad, y código UNSPSC más tipo de contrato en dim_objeto_contractual. Cada dimensión incluye además el miembro «Desconocido» con llave −1, que no se cuenta en la columna de registros.

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
dim_tiempo	Dimensión	fecha_key	—	1.096	dw/ddl/02_dimensiones.sql dw/ddl/04_poblar_dim_tiempo.sql
dim_entidad	Dimensión	entidad_key	—	350	dw/ddl/02_dimensiones.sql
dim_proveedor	Dimensión	proveedor_key	—	54.732	dw/ddl/02_dimensiones.sql
dim_modalidad	Dimensión	modalidad_key	—	43	dw/ddl/02_dimensiones.sql
dim_objeto_contractual	Dimensión	objeto_key	—	6.762	dw/ddl/02_dimensiones.sql
fact_contrato	Hechos	contrato_sk	fecha_firma_key, entidad_key, proveedor_key, modalidad_key, objeto_key	137.016	dw/ddl/03_fact_contrato.sql

La base se crea con dw/ddl/01_crear_base.sql. Los cuatro scripts se ejecutaron en orden sobre una base vacía sin errores. La tabla de hechos contiene las métricas definidas para la granularidad de la Entrega 1 (un contrato electrónico firmado): valor_contrato, valor_contrato_constante, valor_pagado, duracion_dias, dias_publicacion_a_firma y conteo_contratos, además de las dimensiones degeneradas id_contrato, proceso_de_compra y estado_contrato.

1.3 Diagrama del modelo físico

El diagrama se generó con la vista Diagrama ER de DBeaver sobre la base bi_secop ya creada y poblada. Corresponde a un esquema en estrella: la tabla fact_contrato en el centro, con una llave foránea hacia cada una de las cinco dimensiones, y sin relaciones entre dimensiones. El archivo PNG está en /docs/diagramas/modelo_fisico.png.

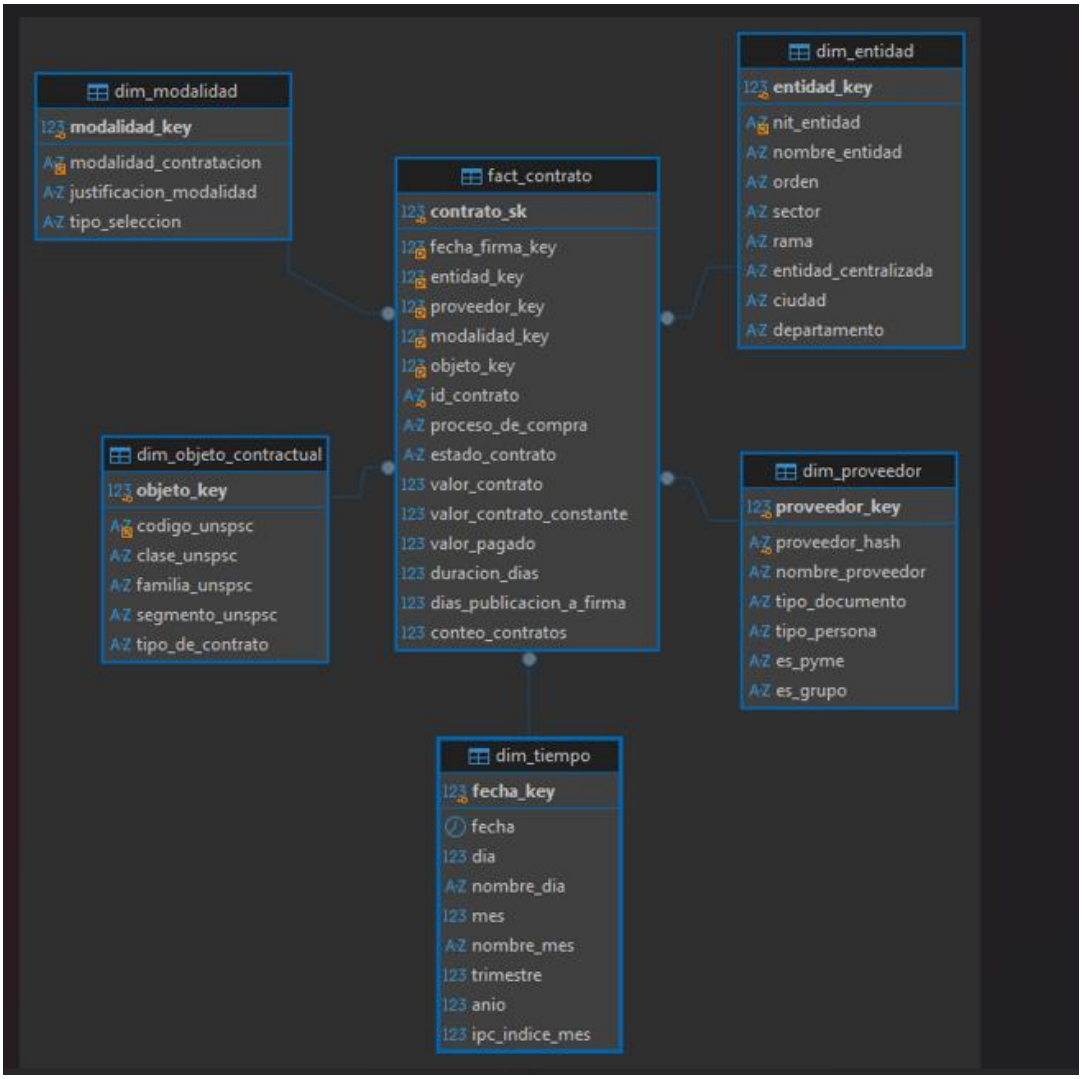


Ilustración 1. Modelo físico en estrella generado desde la base de datos (DBeaver). Fuente: elaboración propia.

1.4 Dimensión de tiempo

La dimensión de tiempo cubre sin huecos del 01/01/2023 al 31/12/2025: 1.096 días, uno por fila, más el miembro desconocido (−1). Ese rango contiene todas las fechas de firma de los contratos de la tabla de hechos; la consulta de conciliación confirma que ningún hecho quedó con fecha_firma_key = −1.

Se pobló en dos partes. El script dw/ddl/04_poblar_dim_tiempo.sql genera el calendario con una consulta recursiva (WITH RECURSIVE) y calcula los atributos de la jerarquía: fecha, día, nombre del día, mes, nombre del mes, trimestre y año (día → mes → trimestre → año). Luego la transformación t_dim_tiempo_ipc.ktr lee la fuente F3 (IPC del DANE) y llena el atributo ipc_indice_mes en los 36 meses del periodo, que se usa para calcular el valor en pesos constantes.

2. Procesos ETL

2.1 Trabajo de carga

El trabajo etl/trabajos/j_carga_completa.kjb ejecuta las seis transformaciones en orden, unidas con saltos que solo continúan si el paso anterior terminó bien: primero las dimensiones y al final los hechos, porque la tabla de hechos busca las llaves en las dimensiones ya cargadas.

Orden: 1) t_dim_tiempo_ipc · 2) t_dim_entidad · 3) t_dim_modalidad · 4) t_dim_objeto_contractual · 5) t_dim_proveedor · 6) t_fact_contrato. Las rutas de los archivos usan la variable ${PROJECT_DIR}, definida en kettle.properties, para que la carga se pueda reproducir en el computador de cualquier integrante.

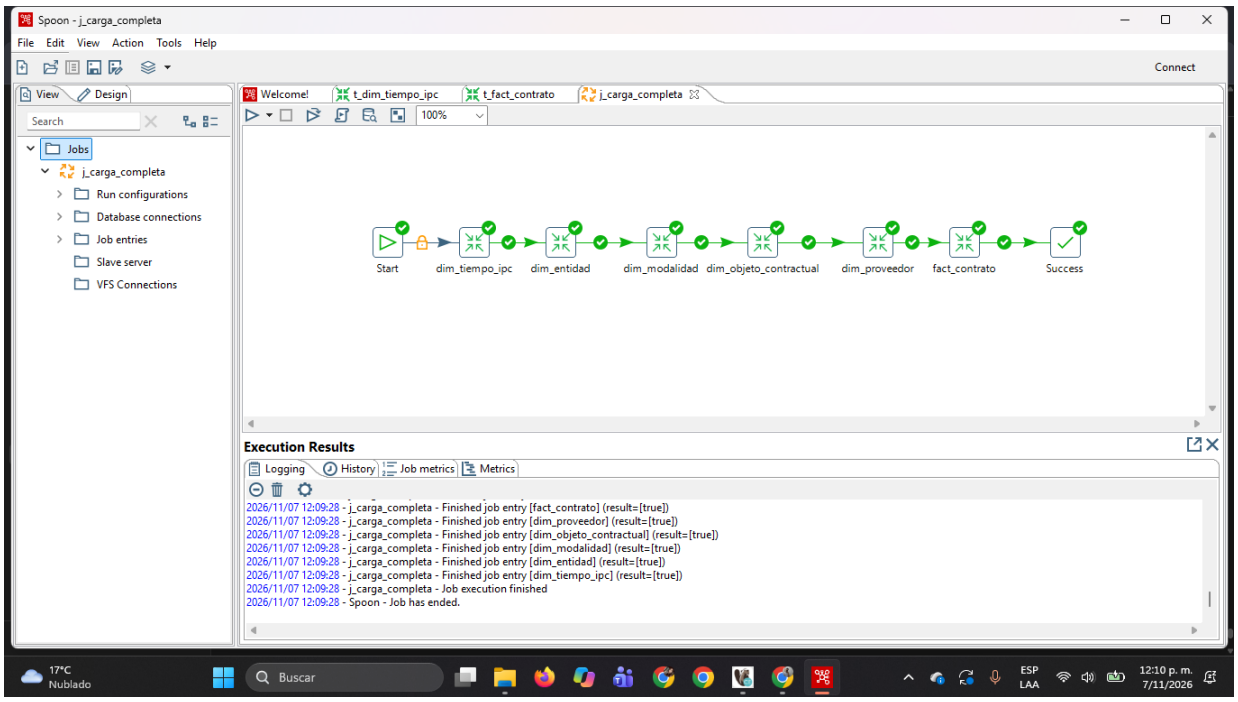


Ilustración 2. Trabajo j_carga_completa.kjb ejecutado completo, con todas las entradas en verde. Fuente: elaboración propia.

2.2 Transformaciones

Los registros se tomaron de las métricas de pasos de la ejecución. En las dimensiones, la columna de rechazos corresponde a filas repetidas que el paso Unique rows descarta para dejar un registro por miembro; no son errores.

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_tiempo_ipc.ktr	F3 (XLSX)	dim_tiempo (ipc_indice_mes)	Microsoft Excel input → Filter rows → Value mapper → Strings cut → Select values → Filter rows → Execute SQL script	217	36	181
t_dim_entidad.ktr	F1 (CSV)	dim_entidad	CSV file input → Select values → String operations → Value mapper → Unique rows (HashSet) → Insert / Update	137.016	350	136.666
t_dim_modalidad.ktr	F1 (CSV)	dim_modalidad	CSV file input → Select values → String operations → Value mapper (×2) → Unique rows (HashSet) → Insert / Update	137.016	43	136.973
t_dim_objeto_contractual.ktr	F1 (CSV)	dim_objeto_contractual	CSV file input → Select values → String operations → Replace in string → Strings cut → Unique rows (HashSet) → Insert / Update	137.016	6.762	130.254
t_dim_proveedor.ktr	F1 (CSV)	dim_proveedor	CSV file input → Select values → String operations → Value mapper (×2) → Add a checksum → User Defined Java Expression → Unique rows (HashSet) → Insert / Update	137.016	54.732	82.284
t_fact_contrato.ktr	F1 (CSV) y F2 (JSON)	fact_contrato	CSV file input + JSON input → Unique rows → Select values → Stream lookup → Formula → Database lookup (×5) → Calculator → Unique rows → Table output	F1: 137.016 F2: 148.228	137.016	F2: 16.385

2.3 Reglas de limpieza aplicadas

Cada problema de calidad de la tabla 2.2 de la Entrega 1 tiene una regla implementada en un paso de PDI identificado por su nombre. Se añaden al final las reglas adicionales que surgieron al construir la carga.

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
Fecha como texto ISO con hora	F1.fecha_de_firma, fecha_de_inicio_del_contrato, fecha_de_fin_del_contrato	Convertir el texto aaaa-MM-dd'T'HH:mm:ss.SSS a tipo fecha	convierte_fechas_f1 (Select values)	137.016
Código UNSPSC con prefijo «V1.»	F1.codigo_de_categoria_principal	Quitar el prefijo y derivar segmento, familia y clase	quita_prefijo_unspsc (Replace in string) y deriva_jerarquia_unspsc (Strings cut)	137.016
Mayúsculas inconsistentes en catálogos	F1.estado_contrato y F1.sector	Recortar espacios y poner mayúscula inicial («terminado» → «Terminado»)	normaliza_texto_hechos y normaliza_texto_entidad (String operations)	24.027 estados («terminado» y «cedido»)
Ciudad «No Definido»	F1.ciudad	Reemplazar por «Desconocida»	ciudad_no_definido (Value mapper)	12.586
Datos personales de contratistas personas naturales	F1.documento_proveedor y proveedor_adjudicado	Reemplazar el documento por su hash SHA-256 y no guardar el nombre de personas naturales	hash_documento (Add a checksum) y oculta_nombre_persona_natural (User Defined Java Expression)	112.901 contratos (47.763 proveedores naturales)
Catálogo en dos idiomas	F1.tipo_de_documento_ordenador_del_gasto	Excluir el campo del modelo (no responde ninguna pregunta); no se propaga a las tablas	selecciona_campos_proveedor (Select values)	137.016
Filas duplicadas en F2	F2 (registro completo, por id_del_portafolio)	Dejar un solo proceso por id_del_portafolio antes del cruce	quita_duplicados_f2 (Unique rows HashSet)	16.385
Fechas de publicación como texto y fuera de alcance	F2.fecha_de_publicacion_del	Convertir a fecha; los contratos sin proceso o sin fecha quedan con días a firma nulo	convierte_fecha_f2 (Select values) y busca_proceso_f2 (Stream lookup)	148.228 convertidas; 59 contratos sin fecha
Departamento de la entidad distinto en F2	F2.departamento_entidad	Tomar el departamento y la entidad solo de F1; de F2 solo se recupera la fecha de publicación	busca_proceso_f2 (Stream lookup)	796
Estructura del libro de Excel	F3, hoja 13	Leer desde la fila de datos, descartar notas al pie, convertir mes a número y año «2009,0» a entero	lee_ipc_f3 (Excel input), quita_notas_al_pie (Filter rows), mes_texto_a_numero (Value mapper), recorta_anio (Strings cut)	4 notas; 213 filas convertidas
Valores «No Definido» en justificación y tipo de documento	F1.justificacion_modalidad_de y tipodocproveedor	Reemplazar por «Desconocida» o «Desconocido»	justificacion_no_definida y tipo_doc_no_definido (Value mapper)	10 y 124
Valores monetarios con decimales en algunas filas	F1.valor_del_contrato y valor_pagado	Tipar como Number tras revisar todo el archivo	lee_contratos_f1 (CSV file input)	137.016

2.4 Evidencia de ejecución

La ejecución completa del trabajo terminó sin errores. El registro (Logging) muestra, para cada transformación, las métricas de lectura (R) y escritura (W) de cada paso; por ejemplo, en t_fact_contrato: lee_contratos_f1 W=137.016, lee_procesos_f2 W=148.228, calcula_metricas R=137.016 W=137.016 y carga_fact_contrato R=137.016 W=137.016. La captura de la ilustración 2 muestra el trabajo terminado y la ilustración 3 las métricas de pasos de la tabla de hechos.

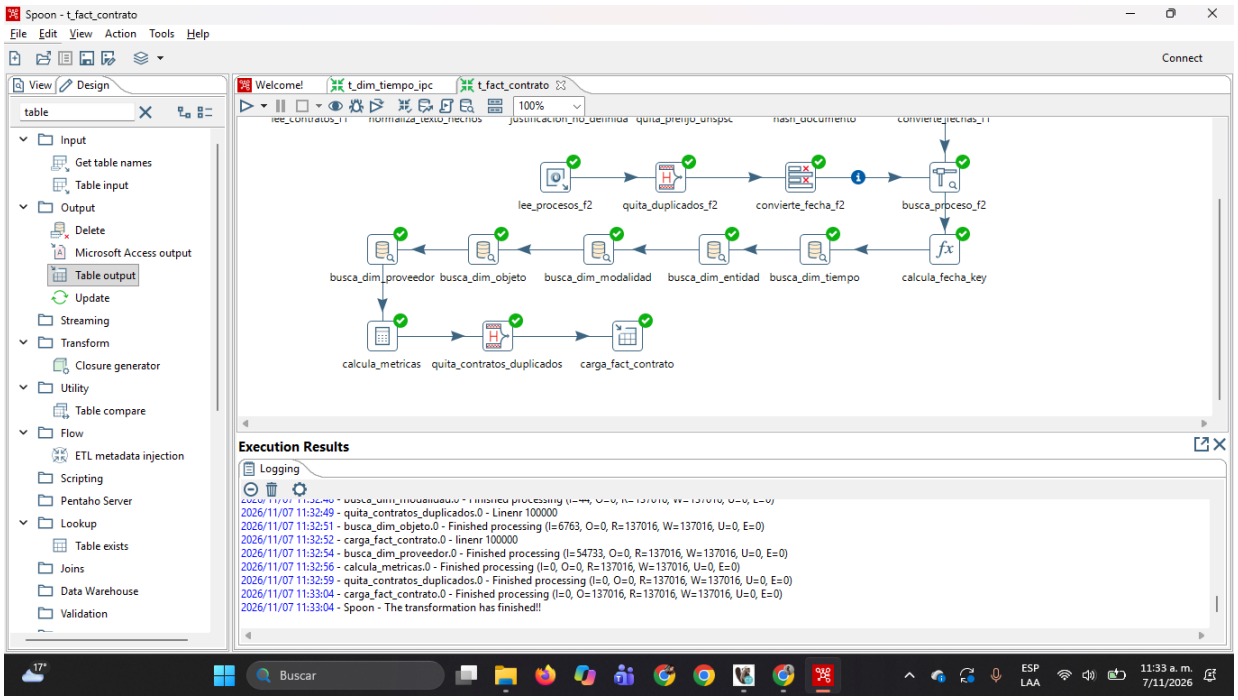


Ilustración 3. Ejecución de t_fact_contrato.ktr terminada sin errores, con las métricas de los pasos. Fuente: elaboración propia.

3. Conciliación

3.1 Conteo por fuente

Los conteos se obtuvieron de las métricas de PDI y de las consultas del Anexo A. En las tres fuentes se cumple: leídos = cargados + descartados.

Fuente	Leídos	Cargados	Descartados	Motivo de los descartes
F1	137.016	137.016	0	Ninguno: todos los contratos se cargaron y ninguno quedó con llaves −1 (consulta 2 del Anexo A).
F2	148.228	131.843	16.385	8.348 filas duplicadas exactas y 8.037 repeticiones del mismo proceso con datos distintos; F2 no se carga como tabla: se usa para obtener la fecha de publicación de cada contrato.
F3	217	36	181	4 filas de notas al pie y 177 meses fuera del periodo 2023–2025.

3.2 Totales de una métrica

Se compara el total de valor_contrato y de valor_pagado calculado sobre el archivo original de F1 (script 03_totales_fuente.py) con el calculado en fact_contrato (consulta 02_totales_dw.sql). También coinciden exactamente los contratos por año: 39.386 (2023), 47.093 (2024) y 50.537 (2025).

Métrica	Total en la fuente	Total en el DW	Diferencia y explicación
valor_contrato (pesos)	13.984.808.354.380,59	13.984.808.354.382	≈ $1: redondeo a dos decimales de DECIMAL(18,2) en contratos cuyo valor trae más decimales en la fuente; despreciable frente al total.

Métrica	Total en la fuente	Total en el DW	Diferencia y explicación
valor_pagado (pesos)	5.711.757.069.134,29	5.711.757.069.178	≈ $44: misma causa de redondeo, en un total de $5,71 billones.

4. Tablero

4.1 Indicadores

El tablero tiene dos páginas en Power BI Desktop y se conecta a la base bi_secop de MySQL por ODBC (DSN bi_secop, controlador MySQL ODBC Unicode). Usa las tablas dim_* y fact_contrato del data warehouse, unidas por las cinco relaciones de la estrella. Cada indicador se muestra en una tarjeta al lado de otra con su referencia.

Indicador	Fórmula (DAX o SQL)	Qué mide	Referencia	Pregunta
Valor contratado del último año	Valor último año = VAR a = MAX(dim_tiempo[anio]) RETURN CALCULATE([Valor constante], dim_tiempo[anio] = a) Var % vs año anterior = DIVIDE([Valor último año] - [Valor año anterior], [Valor año anterior])	Valor contratado en pesos constantes de dic-2025 en el último año del filtro: $5,91 billones en 2025	Periodo anterior: variación frente a 2024 (+57,62 %)	P0
% de contratación directa	% Contratación directa = DIVIDE([Valor directa], [Valor constante]), con Valor directa = CALCULATE([Valor constante], dim_modalidad[tipo_seleccion] = "No competitiva")	Participación del valor adjudicado por modalidades no competitivas: 60,52 %	Promedio departamental: % Directa promedio depto = CALCULATE([% Contratación directa], ALL(dim_entidad))	P0
Días entre publicación y firma	Días publicación a firma = AVERAGE(fact_contrato[dias_publicacion_a_firma])	Días promedio entre la publicación del proceso y la firma del contrato: 4,84	Promedio general: CALCULATE([Días publicación a firma], ALL(dim_modalidad), ALL(dim_entidad))	P1
Concentración en 10 proveedores	% Top 10 proveedores = DIVIDE(SUMX(TOPN(10, VALUES(dim_proveedor[proveedor_key]), [Valor constante]), [Valor constante]), [Valor constante])	Participación de los diez proveedores con más valor contratado: 31,81 %	Total del valor contratado (100 %) del filtro aplicado	P2

4.2 Respuesta a las preguntas de negocio

Las cifras se tomaron del tablero sin filtros aplicados (todo el periodo y todas las entidades) y se verificaron con consultas SQL sobre el data warehouse.

Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
P0	Resumen y P0 · «P0 · Top 10 entidades por valor de contratación directa» y «P0 · % de contratación directa por trimestre»	Barras horizontales ordenadas, porque comparan entidades con nombres largos; línea con marcadores para la tendencia trimestral, porque el eje es una secuencia temporal	La Secretaría de Hacienda de Cundinamarca concentra el mayor valor de contratación directa ($1.242,5 mil millones), seguida del Municipio de Soacha ($1.059,8 mil millones). El 60,52 % del valor del periodo fue no competitivo; el pico ocurre en el primer trimestre de cada año (68,2 %, 78,5 % y 84,7 %) y el mínimo en 2023-T2 (29,6 %).
P1	P1 a P3 · «P1 · Días promedio entre publicación y firma, por modalidad»	Barras horizontales ordenadas de mayor a menor, porque comparan categorías	La licitación pública de obra pública tarda en promedio 87,4 días entre publicación y firma (213 contratos), frente a 1,9 días de la contratación directa (96.806 contratos); la mínima cuantía tarda 14,5 días.
P2	P1 a P3 · «P2 · Top 10 proveedores por valor contratado» y tarjeta «% Top 10 proveedores»	Barras horizontales ordenadas (Top N = 10) más una tarjeta con el porcentaje	Los diez proveedores con más valor concentran el 31,81 % del valor contratado; el primero es Consorcio Mantenimiento Escuelas 2025 ($2.294,1 mil millones), seguido de Bancolombia ($898,3 mil millones).

Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
P3	P1 a P3 · «P3 · Valor contratado por segmento UNSPSC y año»	Columnas agrupadas por año, porque comparan categorías en tres periodos	El segmento 80 (servicios de gestión, profesionales y administrativos) es el de mayor valor y crece de $923,9 mil millones en 2023 a $1.324,4 mil millones en 2025; el segmento 85 (salud) cae de $1.398,2 mil millones en 2023 a $209,7 mil millones en 2024, y el 84 (financieros y seguros) sube a $993,8 mil millones en 2025.

4.3 Capturas del tablero

Las capturas y el archivo tablero_secop.pbix están en /dashboard.

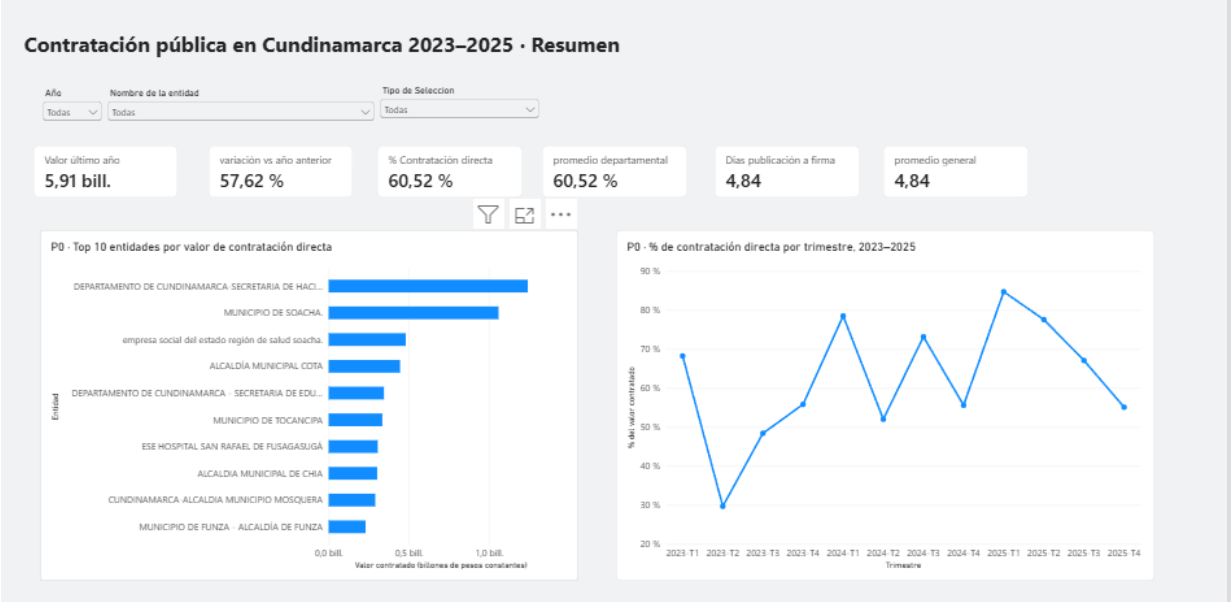


Ilustración 4. Página «Resumen y P0» del tablero. Fuente: elaboración propia.

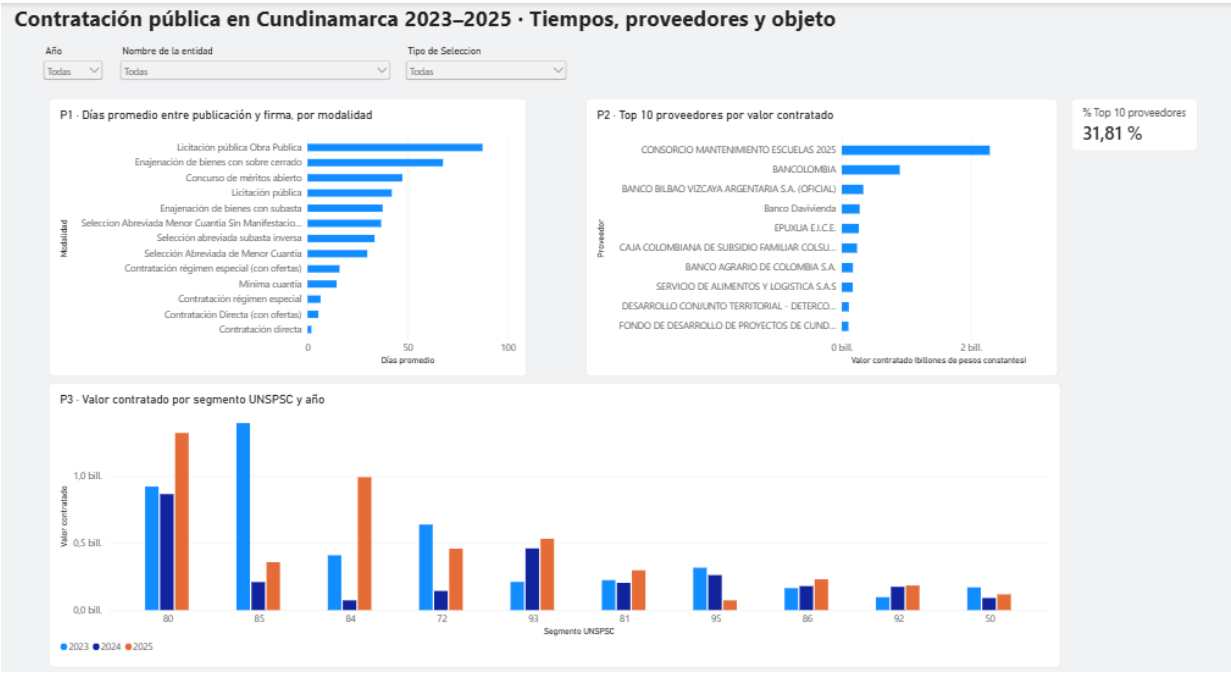


Ilustración 5. Página «P1 a P3» del tablero. Fuente: elaboración propia.

4.4 Filtros

Tres segmentaciones en lista desplegable, sincronizadas en las dos páginas, que afectan a todos los visuales de cada página: Año (dim_tiempo[anio], dimensión de tiempo), Nombre de la entidad (dim_entidad[nombre_entidad]) y Tipo de selección (dim_modalidad[tipo_seleccion]: Competitiva o No competitiva).

Además, los visuales de ranking usan filtros Top N por su medida (10 entidades, 10 proveedores y 10 segmentos). El valor «0» de año y «N/D» de tipo de selección, que corresponden al miembro desconocido, se ocultan en las segmentaciones. En P3 se excluye el segmento «UN», un código mal registrado en el SECOP, mediante la medida Valor constante P3, sin afectar los demás visuales.

Anexos

Anexo A. Consultas de conciliación

Las consultas son iguales a las de /dw/conciliacion. Los totales de la fuente se calculan con dw/conciliacion/03_totales_fuente.py, que lee el CSV de F1 y el JSON de F2 originales y muestra registros, duplicados y la suma de valor_del_contrato y valor_pagado.

```
-- dw/conciliacion/01_conteos_dw.sql
USE bi_secop;
-- 1. Registros por tabla (sin el miembro desconocido -1)
SELECT 'dim_tiempo' AS tabla, COUNT(*) AS registros FROM dim_tiempo WHERE fecha_key > 0
UNION ALL SELECT 'dim_entidad', COUNT(*) FROM dim_entidad WHERE entidad_key > 0
UNION ALL SELECT 'dim_proveedor', COUNT(*) FROM dim_proveedor WHERE proveedor_key > 0
UNION ALL SELECT 'dim_modalidad', COUNT(*) FROM dim_modalidad WHERE modalidad_key > 0
UNION ALL SELECT 'dim_objeto_contractual', COUNT(*) FROM dim_objeto_contractual WHERE objeto_key > 0
UNION ALL SELECT 'fact_contrato', COUNT(*) FROM fact_contrato;
-- 2. Hechos que apuntan al miembro desconocido por dimensión
SELECT SUM(fecha_firma_key = -1) AS sin_fecha, SUM(entidad_key = -1) AS sin_entidad,
       SUM(proveedor_key = -1) AS sin_proveedor, SUM(modalidad_key = -1) AS sin_modalidad,
       SUM(objeto_key = -1) AS sin_objeto
FROM fact_contrato;
-- 3. Contratos sin proceso en F2
SELECT COUNT(*) AS contratos_sin_proceso_en_f2 FROM fact_contrato WHERE dias_publicacion_a_firma IS NULL;
-- 4. Meses de dim_tiempo sin IPC
SELECT COUNT(DISTINCT anio, mes) AS meses_sin_ipc FROM dim_tiempo WHERE fecha_key > 0 AND ipc_indice_mes
IS NULL;
```

```
-- dw/conciliacion/02_totales_dw.sql
USE bi_secop;
SELECT COUNT(*) AS contratos, SUM(valor_contrato) AS total_valor_contrato,
       SUM(valor_pagado) AS total_valor_pagado, SUM(valor_contrato_constante) AS total_valor_constante
FROM fact_contrato;
SELECT t.anio, COUNT(*) AS contratos, SUM(f.valor_contrato) AS total_valor_contrato
FROM fact_contrato f JOIN dim_tiempo t ON t.fecha_key = f.fecha_firma_key
GROUP BY t.anio ORDER BY t.anio;
```

Anexo B. Capturas adicionales

Capturas de las transformaciones de las dimensiones ejecutadas en PDI, con sus métricas de pasos.

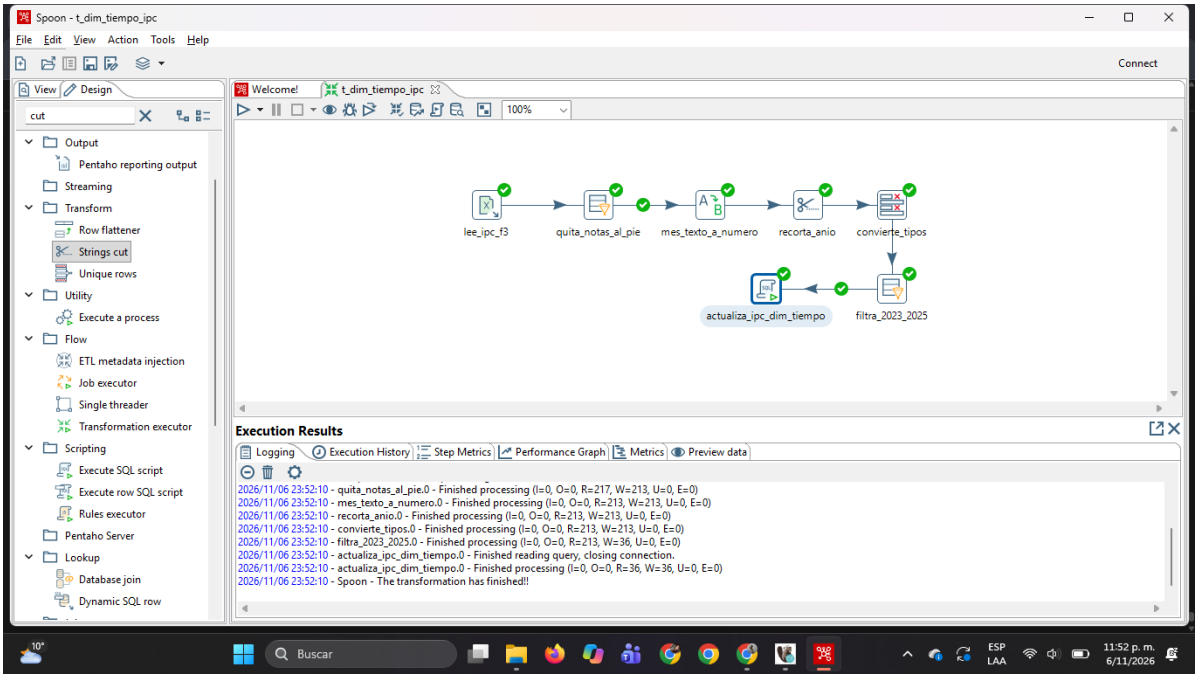
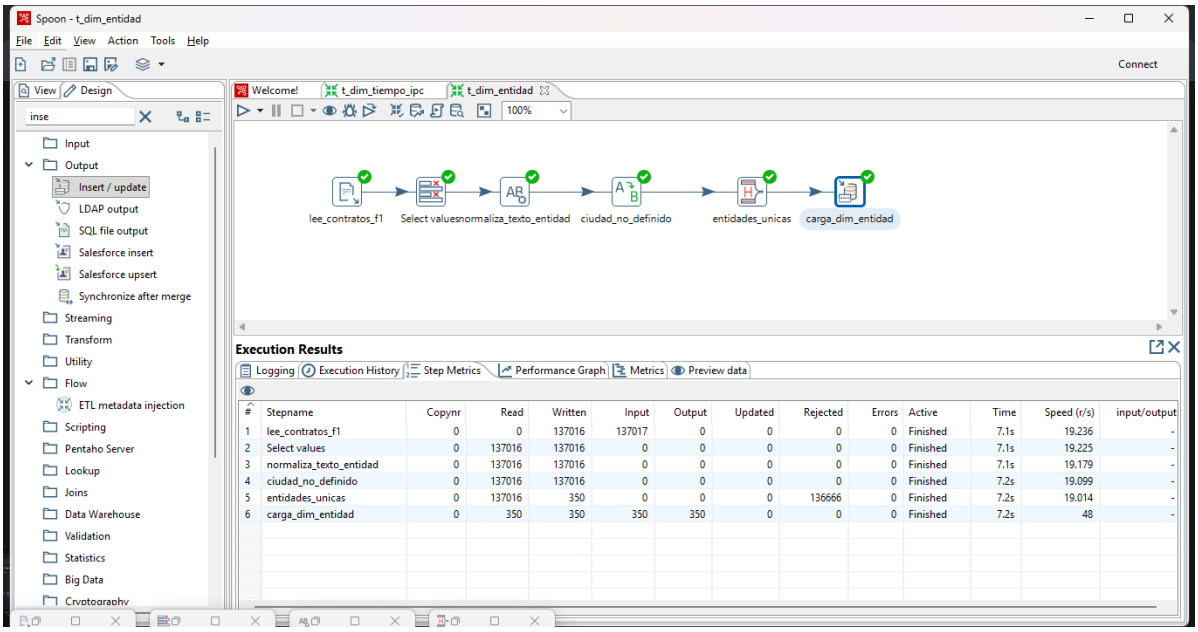


Ilustración 6. Transformación t_dim_tiempo_ipc.ktr. Fuente: elaboración propia.



#	Stepname	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors	Active	Time	Speed (r/s)	input/output
1	lee_contratos_f1	0	0	137016	137017	0	0	0	0	Finished	7.1s	19.236	-
2	Select values	0	137016	137016	0	0	0	0	0	Finished	7.1s	19.225	-
3	normaliza_texto_entidad	0	137016	137016	0	0	0	0	0	Finished	7.1s	19.179	-
4	ciudad_no_definido	0	137016	137016	0	0	0	0	0	Finished	7.2s	19.099	-
5	entidades_unicas	0	137016	350	0	0	0	136666	0	Finished	7.2s	19.014	-
6	carga_dim_entidad	0	350	350	350	350	0	0	0	Finished	7.2s	48	-

Ilustración 7. Transformación t_dim_entidad.ktr. Fuente: elaboración propia.

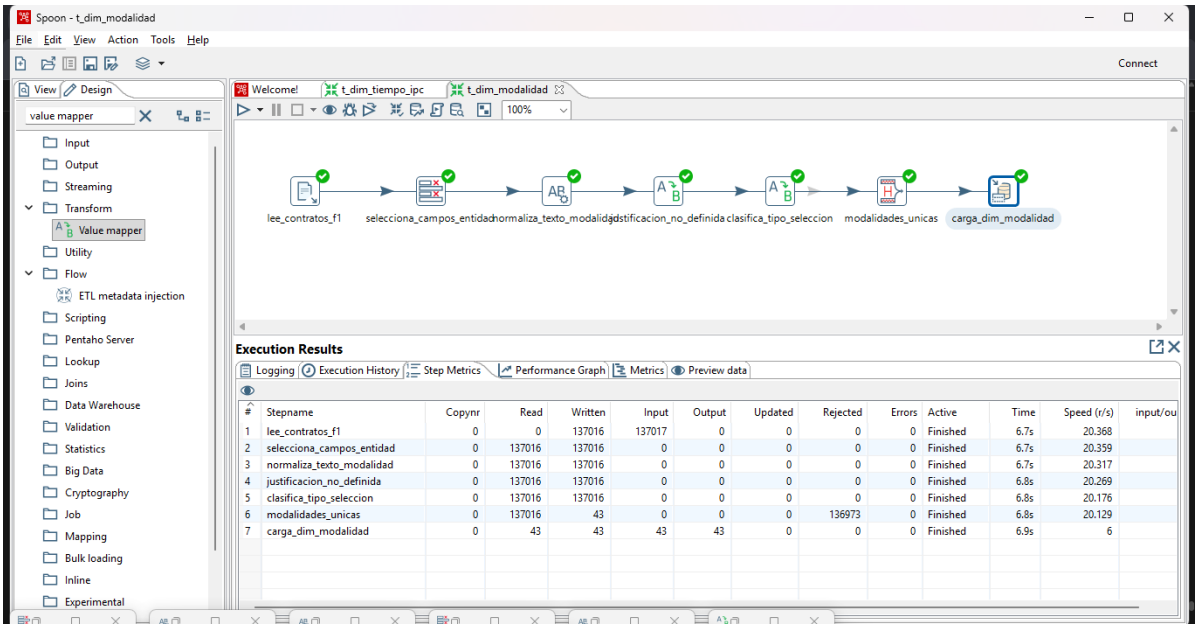


Ilustración 8. Transformación t_dim_modalidad.ktr. Fuente: elaboración propia.

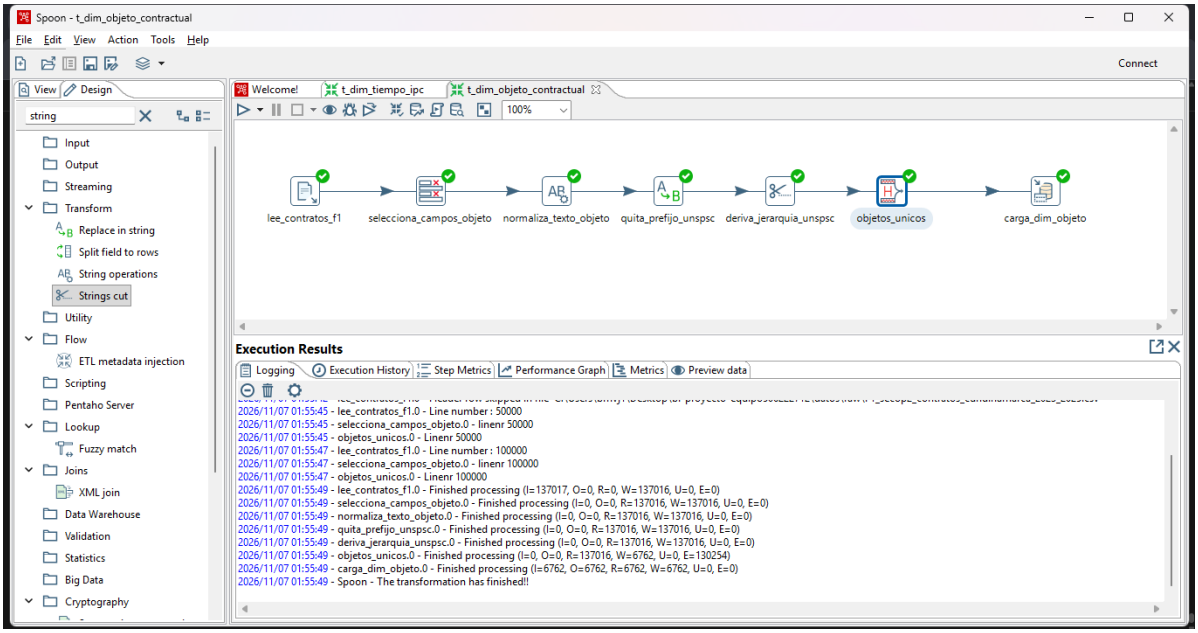


Ilustración 9. Transformación t_dim_objeto_contractual.ktr. Fuente: elaboración propia.

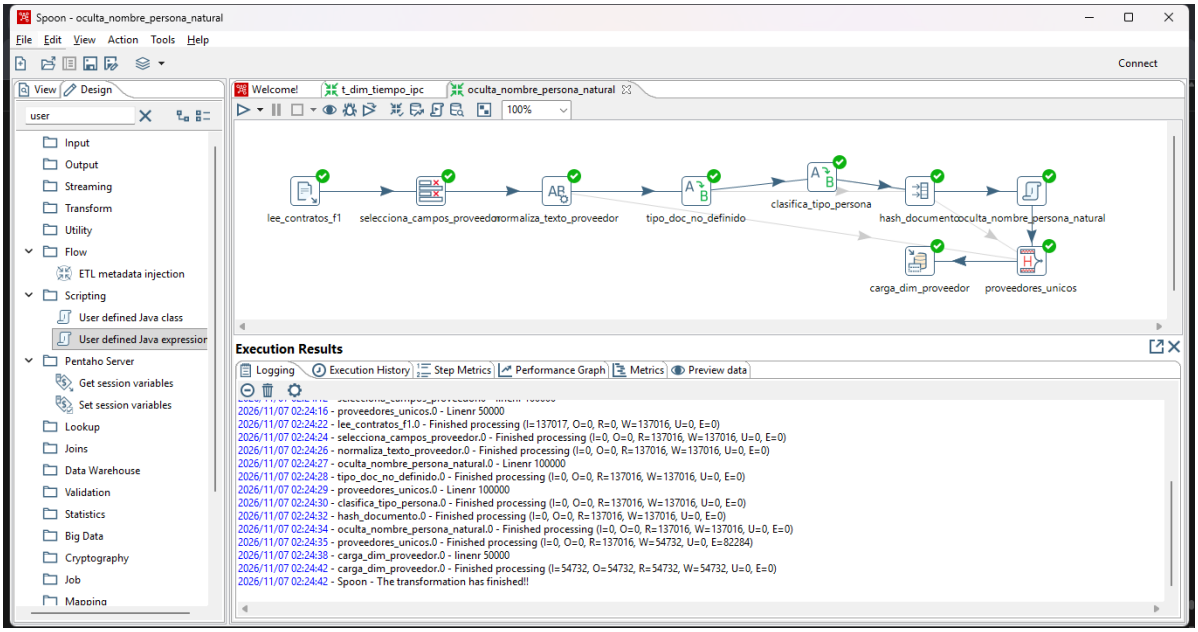


Ilustración 10. Transformación t_dim_proveedor.ktr. Fuente: elaboración propia.