Business Intelligence

Proyecto final · Entrega 3

Modelo predictivo

Vigilancia de la contratación pública en Cundinamarca con datos del SECOP II (2023–2025)

Integrante	Código
Luis Alfredo Bañol Falla	506222712
Juan Camilo Londoño Cifuentes	507241030
Jennifer Urueña Gutiérrez	507241702

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	13/11/2026
Repositorio	https://github.com/Zierk110/bi-proyecto-equipo506222712
Entorno del modelo	Python 3.11 en Jupyter Notebook (local), con pandas, scikit-learn y SQLAlchemy

Resumen de la entrega

Se responde la pregunta P4 de la Entrega 1: ¿cuánto valor contratará cada entidad de Cundinamarca por mes en 2026 y cuáles superarán su promedio 2023–2025? El modelo predice el valor contratado por una entidad en un mes, en millones de pesos constantes de diciembre de 2025, a partir de lo que esa entidad contrató el año anterior, del mes y del tipo de entidad. Los datos (12.600 registros entidad-mes de 350 entidades) se extrajeron del data warehouse de la Entrega 2.

Se compararon una regresión lineal y un bosque aleatorio, entrenados con 2024 y evaluados con 2025. Se eligió el bosque aleatorio, con un MAE de 1.119,1 millones por entidad y mes, 53,0 millones menos que la regresión lineal (1.172,1). Sin embargo, no alcanzó el criterio de éxito: su MAE fue 1,0 % mayor que el de la referencia sin modelo (1.107,9), y subestimó el total de 2025 porque ese año la contratación creció 57,6 %. Su fortaleza está en ordenar a las entidades: acertó 17 de las 20 entidades que más contrataron en 2025.

Para 2026 el modelo pronostica $4,42 billones en pesos constantes, encabezados por el Municipio de Soacha ($186,2 mil millones), la Alcaldía de Chía ($145,0 mil millones) y la Alcaldía de Facatativá ($134,7 mil millones). De las 70 entidades que más contratan, 45 superarían su promedio mensual 2023–2025. Esto apoya la decisión de concentrar las auditorías del Plan de Vigilancia 2027 en ese grupo, usando el pronóstico como orden de prioridad y no como monto exacto.

1. Comprensión del negocio

1.1 Pregunta y decisión

Pregunta (P4 de la tabla 1.3 de la Entrega 1, de tipo BA): ¿cuánto valor contratará cada entidad por mes en 2026 y cuáles superarán su promedio 2023–2025?

Decisión que apoya: la Contralora Auxiliar de Planeación debe proponer el Plan de Vigilancia y Control Fiscal (PVCF) 2027, que audita la contratación ejecutada en 2026, con un número limitado de auditores. Con las predicciones ordena a las entidades según el valor que se espera que contraten en 2026 y señala las que superarían su promedio histórico, para asignar primero a esas entidades los equipos de auditoría y programar el seguimiento en los meses de mayor contratación.

1.2 Variable objetivo y tipo de problema

Elemento	Respuesta
Variable objetivo	valor_millones: valor contratado por una entidad en un mes (millones de pesos constantes de diciembre de 2025)
Tipo de problema	Regresión
Unidad de predicción	Una predicción por entidad y mes

1.3 Criterio de éxito

En el conjunto de prueba (los 12 meses de 2025), el MAE del modelo elegido debe ser al menos 10 % menor que el MAE de la referencia que usaría un analista sin modelo: repetir, para cada mes, el promedio mensual que contrató la entidad el año anterior. Con el MAE de esa referencia en la prueba (1.107,9 millones por entidad y mes), el criterio equivale a un MAE menor a 997,1 millones por entidad y mes.

2. Comprensión de los datos

2.1 Consulta de extracción

La consulta (igual a modelo/extraccion.sql) une la tabla de hechos fact_contrato con dim_tiempo (mes de firma), dim_entidad (atributos de la entidad) y dim_modalidad (para separar el valor de contratación directa). Agrega los contratos por entidad y mes, completa con cero los meses en que una entidad no firmó contratos (producto cruzado de entidades por meses y unión externa) y filtra los miembros desconocidos (llave −1) y el periodo 2023–2025.

```
-- modelo/extraccion.sql
-- Conjunto de datos del modelo predictivo (Entrega 3), extraído del data warehouse bi_secop (MySQL
8.4).
-- Una fila por entidad y mes (enero de 2023 a diciembre de 2025): 350 entidades x 36 meses.
-- Une fact_contrato con dim_tiempo (mes de firma), dim_entidad (atributos de la entidad) y
dim_modalidad (tipo de seleccion).
-- Los meses sin contratos se completan con cero (CROSS JOIN de entidades por meses + LEFT JOIN).
-- Filtra los miembros desconocidos (llave -1). Valores en millones de pesos constantes de diciembre de
2025.
WITH meses AS (
    SELECT DISTINCT anio, mes
    FROM dim_tiempo
    WHERE fecha_key > 0 AND anio BETWEEN 2023 AND 2025
),
agregado AS (
    SELECT f.entidad_key,
           t.anio,
           t.mes,
           COUNT(*)                         AS contratos,
           SUM(f.valor_contrato_constante)  AS valor,
           SUM(CASE WHEN m.tipo_seleccion = 'No competitiva'
                    THEN f.valor_contrato_constante ELSE 0 END) AS valor_directa
    FROM fact_contrato f
    JOIN dim_tiempo    t ON t.fecha_key     = f.fecha_firma_key
    JOIN dim_modalidad m ON m.modalidad_key = f.modalidad_key
    WHERE t.fecha_key > 0
    GROUP BY f.entidad_key, t.anio, t.mes
)
SELECT e.entidad_key,
       e.nombre_entidad,
       e.orden,
       e.sector,
       e.rama,
       e.entidad_centralizada,
       ms.anio,
       ms.mes,
       COALESCE(a.contratos, 0)                    AS contratos,
       COALESCE(a.valor, 0) / 1000000              AS valor_millones,
       COALESCE(a.valor_directa, 0) / 1000000      AS valor_directa_millones
FROM dim_entidad e
CROSS JOIN meses ms
LEFT JOIN agregado a
       ON a.entidad_key = e.entidad_key
      AND a.anio = ms.anio
      AND a.mes  = ms.mes
WHERE e.entidad_key > 0
ORDER BY e.entidad_key, ms.anio, ms.mes;
```

2.2 Descripción del conjunto de datos

El conjunto tiene 12.600 registros (350 entidades × 36 meses) y cubre de enero de 2023 a diciembre de 2025. No tiene nulos en origen. Las variables del año anterior que usa el modelo se derivan de estas columnas (sección 3.2).

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
valor_millones	Numérica	Objetivo	fact_contrato.valor_contrato_constante (suma)	Valor contratado por la entidad en el mes, en millones de pesos constantes
entidad_key	Entera	Identificador (no es entrada)	dim_entidad.entidad_key	Llave de la entidad; une las predicciones con la dimensión
nombre_entidad	Texto	Identificador (no es entrada)	dim_entidad.nombre_entidad	Nombre de la entidad
orden	Categórica	Entrada	dim_entidad.orden	Territorial, Nacional o Corporación Autónoma
sector	Categórica	Entrada	dim_entidad.sector	Sector de la entidad (18 valores)
rama	Categórica	Entrada	dim_entidad.rama	Rama del poder (4 valores)
entidad_centralizada	Categórica	Entrada	dim_entidad.entidad_centralizada	Centralizada o Descentralizada
anio	Entera	División temporal	dim_tiempo.anio	Año de firma; separa entrenamiento (2024) y prueba (2025)
mes	Categórica	Entrada	dim_tiempo.mes	Mes de firma (1 a 12), para la estacionalidad
contratos	Numérica	Insumo de variables derivadas	fact_contrato.conteo_contratos (conteo)	Contratos firmados por la entidad en el mes
valor_directa_millones	Numérica	Insumo de variables derivadas	fact_contrato.valor_contrato_constante con dim_modalidad.tipo_seleccion = «No competitiva»	Valor del mes adjudicado por modalidades no competitivas

2.3 Distribución de la variable objetivo

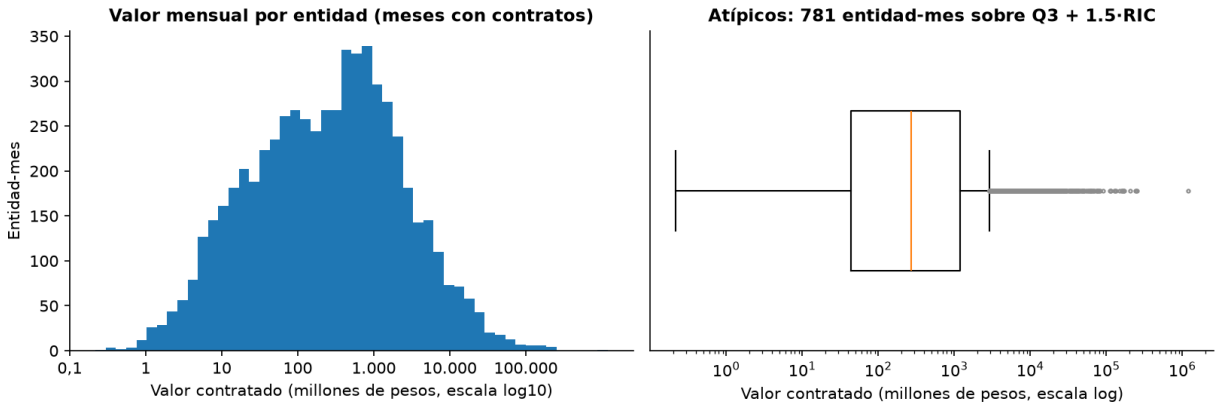


Ilustración 1. Distribución del valor contratado por entidad y mes (escala logarítmica). Fuente: elaboración propia con el notebook modelo_predictivo.ipynb.

La variable objetivo es muy asimétrica. El 52,4 % de los registros (6.601 entidad-mes) vale cero, porque la entidad no firmó contratos ese mes; por eso la mediana es 0 y la media es 1.211,4 millones. El rango va de 0 a 1.197.551,9 millones (≈ $1,2 billones), un solo contrato del Fondo de Pasivo Social de Ferrocarriles Nacionales en abril de 2023. El percentil 75 es 225,3 millones, el 95 es 3.874,9 y el 99 es 20.324,2.

Entre los meses con contratos, 781 registros superan el límite de atípicos del rango intercuartílico (Q3 + 1,5·RIC = 2.901,1 millones). Son contratos grandes y reales (obras, convenios y seguros), no errores, por lo que no se eliminan; se limita su peso en el entrenamiento con un tope en el percentil 99 (sección 3.1).

2.4 Análisis exploratorio

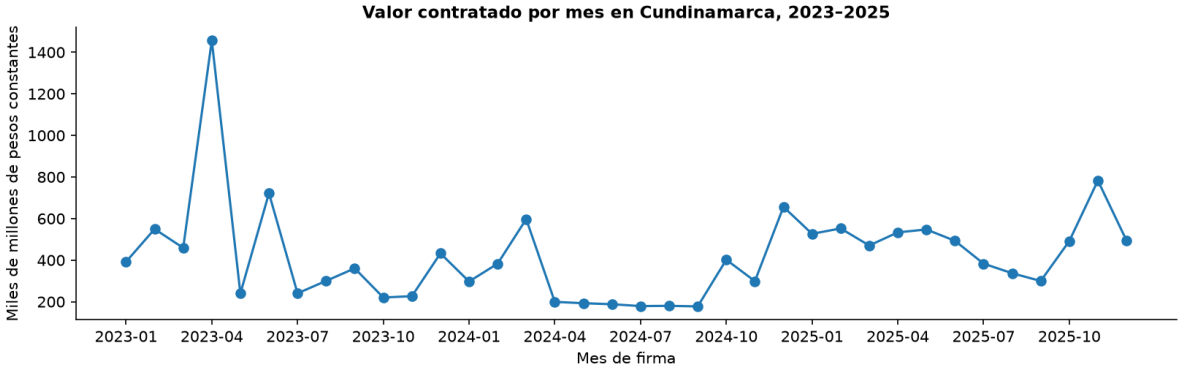


Ilustración 2. Valor contratado por mes en Cundinamarca, 2023–2025. Fuente: elaboración propia con el notebook modelo_predictivo.ipynb.

El total mensual varía mucho: el pico de abril de 2023 ($1,46 billones) lo explica un solo contrato atípico, y 2024 fue un año bajo ($3,75 billones) frente a 2023 ($5,60 billones) y 2025 ($5,91 billones). Hay meses de mayor contratación al inicio y al final de cada año (febrero–abril y noviembre–diciembre), lo que justifica usar el mes como variable de entrada.

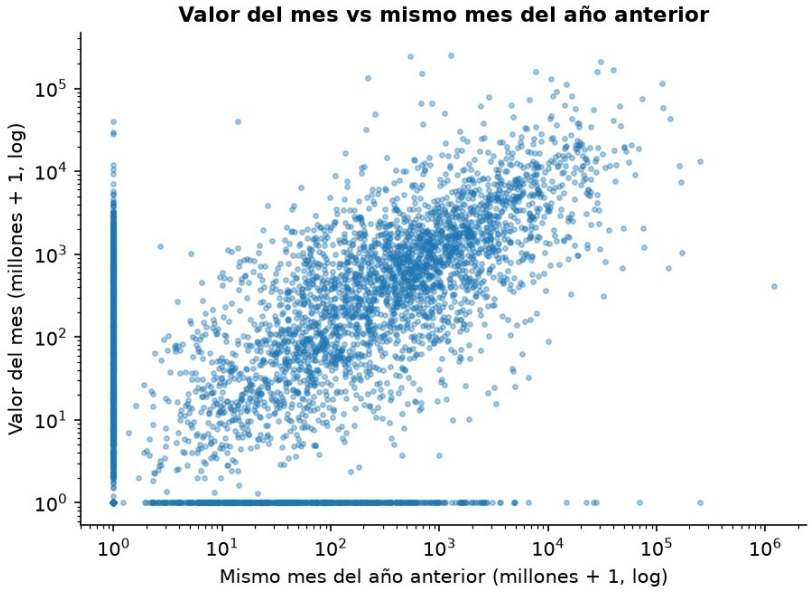


Ilustración 3. Valor del mes frente al valor del mismo mes del año anterior (escala logarítmica). Fuente: elaboración propia con el notebook modelo_predictivo.ipynb.

Las entidades que contrataron mucho en un mes tienden a contratar mucho en el mismo mes del año siguiente: la correlación de Spearman es 0,67, y sube a 0,69 con el promedio mensual del año anterior. La nube es ancha y hay muchos puntos sobre los ejes (meses en cero en uno de los dos años), lo que anticipa errores grandes en meses puntuales.

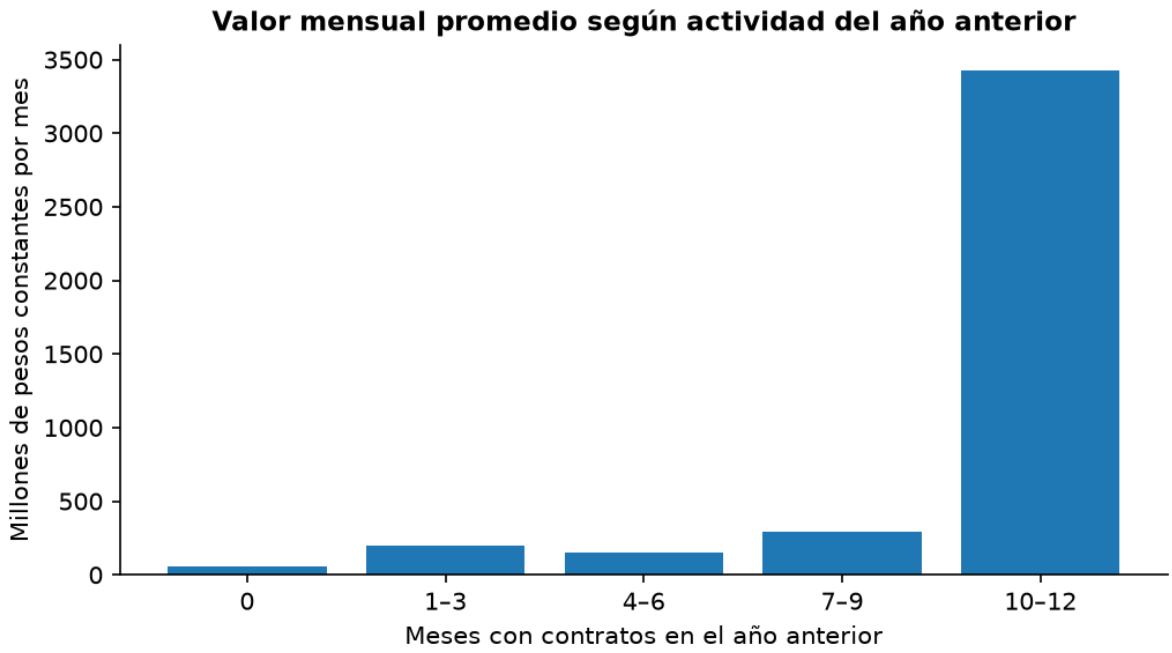


Ilustración 4. Valor mensual promedio según los meses con contratos del año anterior. Fuente: elaboración propia con el notebook modelo_predictivo.ipynb.

La regularidad del año anterior separa claramente a las entidades: las que contrataron en 10 a 12 meses del año anterior promedian 3.428,1 millones por mes (mediana 566,6), mientras que las que no contrataron ningún mes promedian 54,3 millones. Por eso los meses activos del año anterior entran como variable derivada.

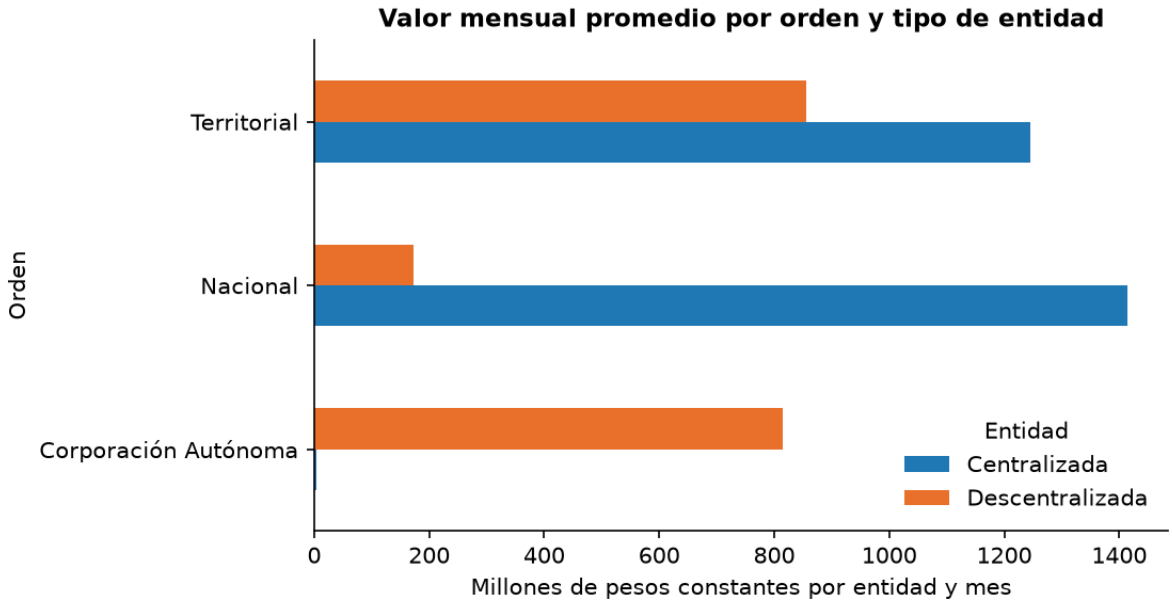


Ilustración 5. Valor mensual promedio por orden y tipo de entidad. Fuente: elaboración propia con el notebook modelo_predictivo.ipynb.

Las entidades centralizadas de orden nacional (1.414,5 millones por mes) y territorial (1.246,0) contratan más que las descentralizadas del mismo orden (172,0 y 855,6). El tipo de entidad aporta información, aunque menos que el comportamiento del año anterior.

3. Preparación de los datos

3.1 Limpieza y transformación

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Nulos (sin año anterior)	Variables derivadas del año anterior	Los registros de 2023 no tienen año anterior en el DW: se usan solo como insumo para calcular las variables de 2024 y no entran como filas de entrenamiento	4.200
Nulos (división por cero)	pct_directa_anio_ant	Si la entidad no contrató nada el año anterior, el porcentaje de contratación directa no existe; se imputa 0	2.280
Nulos (meses sin contratos)	valor_millones, contratos	Los meses sin contratos se completan con 0 en la consulta SQL, porque contratar 0 es un valor real	6.601
Atípicos (objetivo)	valor_millones (entrenamiento)	Tope en el percentil 99 del entrenamiento (15.276,0 millones). La prueba se evalúa con el valor real, sin tope	42
Atípicos (entradas)	valor_mismo_mes_anio_ant y media_mensual_anio_ant	Mismo tope de 15.276,0 millones, calculado solo con el entrenamiento y aplicado a entrenamiento y prueba	111 y 132
Codificación categórica	mes, orden, sector, rama, entidad_centralizada	One-hot encoding (OneHotEncoder, ignora categorías nuevas en la prueba). Con las numéricas quedan 45 columnas de entrada	—
Escalado	6 variables numéricas	Estandarización (StandardScaler) ajustada con el entrenamiento; se aplica igual a los dos algoritmos	—
Predicciones negativas	Predicción de los modelos	Se recortan a 0, porque no existe valor contratado negativo	—

3.2 Variables derivadas

Todas las variables derivadas se calculan con el año calendario anterior completo, que ya se conoce cuando se pronostica el año siguiente; por eso el modelo puede pronosticar los 12 meses de 2026 con los datos de 2025.

Variable nueva	Cómo se calcula	Por qué puede ayudar	¿Se conoce antes del hecho?
media_mensual_anio_ant	Valor anual de la entidad en el año anterior / 12	Resume el tamaño de contratación habitual de la entidad	Sí
valor_mismo_mes_anio_ant	Valor de la entidad en el mismo mes del año anterior	Recoge la estacionalidad propia de cada entidad	Sí
contratos_anio_ant	Contratos firmados por la entidad en el año anterior	Mide el volumen de actividad contractual	Sí
contratos_mismo_mes_anio_ant	Contratos de la entidad en el mismo mes del año anterior	Estacionalidad en número de contratos	Sí
meses_activos_anio_ant	Meses del año anterior con al menos un contrato	Separa entidades que contratan todo el año de las esporádicas	Sí
pct_directa_anio_ant	Valor no competitivo / valor total del año anterior	Perfil de contratación de la entidad, ligado a la pregunta P0	Sí

3.3 División en entrenamiento y prueba

Conjunto	Registros	Periodo o proporción
Entrenamiento	4.200	Objetivo: enero–diciembre de 2024 (variables calculadas con 2023)
Prueba	4.200	Objetivo: enero–diciembre de 2025 (variables calculadas con 2024)

La división es temporal: el modelo se entrena con el pasado y se prueba con el año más reciente, que no ve durante el entrenamiento. Para el pronóstico de 2026 se reentrena el algoritmo elegido, con los mismos parámetros, con 2024 y 2025 (8.400 registros).

4. Modelado

4.1 Algoritmos

Los dos algoritmos se entrenaron con los mismos 4.200 registros de 2024 y las mismas 11 variables de entrada (45 columnas después de la codificación), dentro de un Pipeline de scikit-learn con el mismo preprocesamiento.

Algoritmo	Por qué se eligió	Parámetros usados
Regresión lineal	Algoritmo visto en clase; sirve de línea base interpretable: supone que el valor del mes es una suma ponderada del comportamiento del año anterior, del mes y del tipo de entidad	Valores por defecto (LinearRegression, fit_intercept=True)
Bosque aleatorio	Algoritmo visto en clase; captura relaciones no lineales y combinaciones entre variables (por ejemplo, entidades grandes en enero) y es menos sensible a los valores extremos que la regresión lineal	RandomForestRegressor: n_estimators=300, max_depth=10, min_samples_leaf=5, random_state=42

5. Evaluación

5.1 Métricas sobre el conjunto de prueba

Regresión

Algoritmo	MAE	RMSE	Interpretación en unidades del caso
Regresión lineal	1.172,1	8.004,9	Se equivoca en promedio 1.172 millones por entidad y mes. El RMSE, casi 7 veces el MAE, muestra que unos pocos meses de entidades grandes concentran errores enormes.
Bosque aleatorio	1.119,1	8.017,7	Se equivoca en promedio 1.119 millones por entidad y mes; en la mitad de los casos el error es menor a 83,6 millones. El RMSE alto se debe a los contratos muy grandes: las 20 entidades que más contrataron concentran el 71,8 % del error.
Referencia: promedio mensual del año anterior	1.107,9	7.681,9	Lo que haría un analista sin modelo: repetir cada mes el promedio mensual de la entidad en 2024.

Las unidades son millones de pesos constantes de diciembre de 2025 por entidad y mes. A nivel de todo el departamento, el bosque aleatorio predijo $2,50 billones para 2025 frente a $5,91 billones reales: el error mensual promedio del total es 55,6 %, porque se entrenó con 2024, un año bajo, y en 2025 la contratación creció 57,6 %, sobre todo en noviembre ($782,8 mil millones reales frente a $195,1 predichos).

Donde el modelo sí es útil es en ordenar a las entidades. Al sumar sus predicciones de 2025 por entidad, el orden coincide en buena medida con el real (correlación de Spearman de 0,79): de las 20 entidades que más

contrataron en 2025, el modelo identificó 17, y de las 50 primeras, 43. Las 20 que el modelo señaló como mayores contrataron en realidad el 69,5 % del valor de 2025.

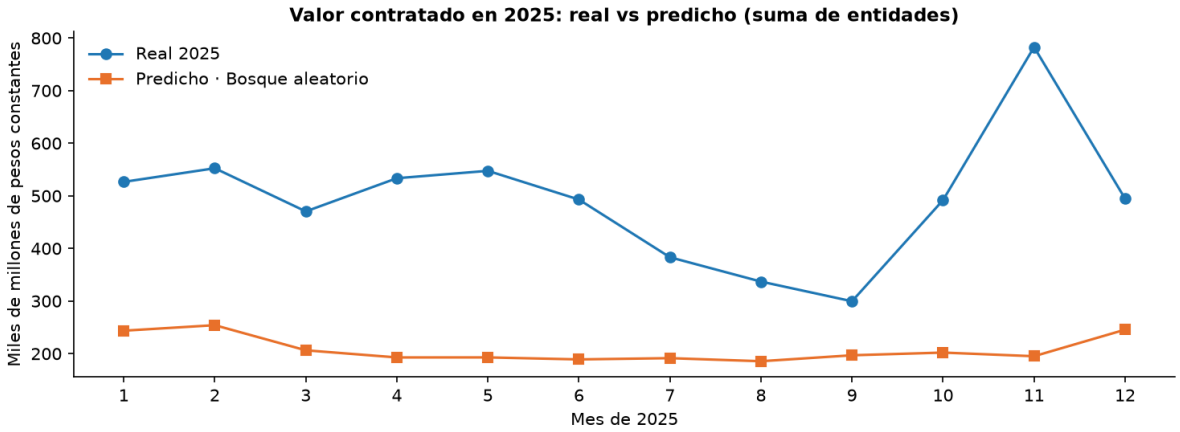


Ilustración 6. Valor contratado en 2025 por mes: real frente a lo predicho por el bosque aleatorio (suma de entidades). Fuente: elaboración propia con el notebook modelo_predictivo.ipynb.

5.2 Comparación y elección

Se elige el bosque aleatorio: su MAE en 2025 es 53,0 millones por entidad y mes menor que el de la regresión lineal (1.119,1 frente a 1.172,1), con los mismos datos de prueba. Los RMSE son casi iguales (8.017,7 frente a 8.004,9), así que la regresión lineal no compensa su mayor error típico con menos errores extremos.

Ninguno de los dos mejoró de forma clara a la referencia sin modelo (MAE 1.107,9). El valor contratado por una entidad en un mes depende de contratos grandes y puntuales que no se repiten de un año a otro, y el modelo solo tiene un año de historia para aprender.

5.3 Variables más importantes

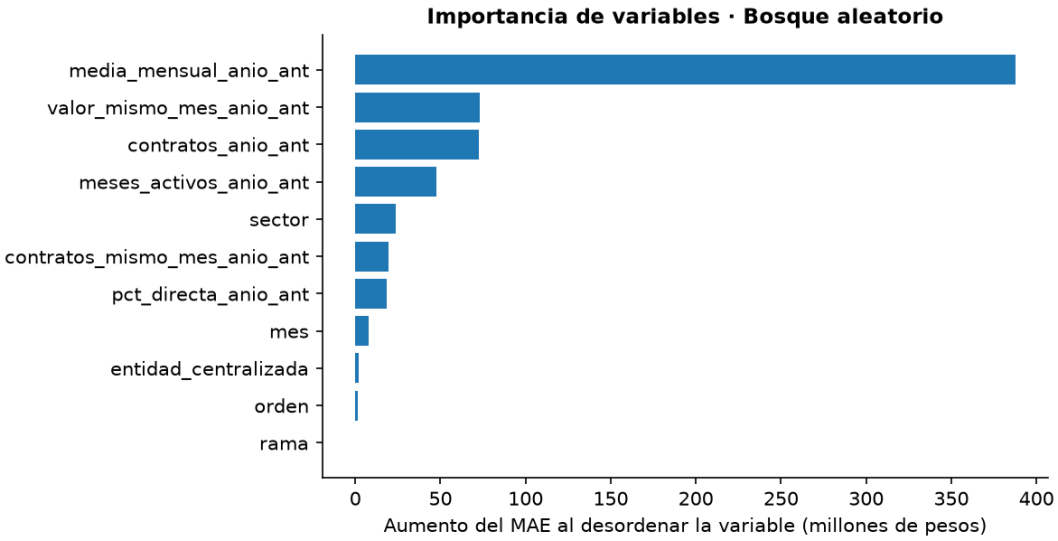


Ilustración 7. Importancia por permutación de las variables del bosque aleatorio sobre la prueba (aumento del MAE al desordenar cada variable). Fuente: elaboración propia con el notebook modelo_predictivo.ipynb.

La variable más importante es el promedio mensual del año anterior: si se desordena, el MAE aumenta 387,5 millones por entidad y mes. Le siguen el valor del mismo mes del año anterior (73,0), los contratos del año

anterior (72,7) y los meses activos del año anterior (47,7). El sector aporta 23,5 millones, y el mes, el orden, la rama y si la entidad es centralizada casi no aportan una vez se conoce su comportamiento del año anterior.

Para la Contraloría, esto significa que el mejor indicador de cuánto contratará una entidad es cuánto y con qué regularidad contrató el año anterior; el tipo de entidad y el calendario añaden poco.

5.4 Criterio de éxito

Criterio (sección 1.3)	Valor obtenido	¿Se alcanzó?
MAE del modelo elegido al menos 10 % menor que el de la referencia (promedio mensual del año anterior), es decir, menor a 997,1 millones por entidad y mes	MAE = 1.119,1 millones por entidad y mes (1,0 % mayor que la referencia)	No

El criterio no se alcanzó. El bosque aleatorio no debe usarse para fijar montos exactos por mes, pero sí para ordenar a las entidades por el valor que se espera que contraten (17 de las 20 mayores de 2025 acertadas). Para mejorar el modelo se necesita más historia (años anteriores a 2023) y variables del presupuesto aprobado de cada entidad.

5.5 Respuesta a la pregunta de negocio

¿Cuánto contratará cada entidad por mes en 2026? El modelo pronostica $4,42 billones en pesos constantes para 2026 (frente a $5,91 billones reales en 2025), con los meses más altos en febrero ($473,6 mil millones), enero ($431,5 mil millones) y diciembre ($411,9 mil millones). Por las razones de la sección 5.1, el total probablemente está subestimado.

Las 10 entidades con mayor valor pronosticado para 2026 son: Municipio de Soacha ($186,2 mil millones), Alcaldía de Chía ($145,0), Alcaldía de Facatativá ($134,7), Municipio de Tocancipá ($130,9), Alcaldía de Cota ($128,9), Alcaldía de Madrid ($127,7), Alcaldía de Zipaquirá ($120,2), Departamento de Cundinamarca – Secretaría de Educación ($116,0), Alcaldía de Cajicá ($113,2) y Alcaldía de Fusagasugá ($113,0).

¿Cuáles superarán su promedio 2023–2025? De las 70 entidades que más contratan (más de $8.674 millones al año en promedio), 45 superarían en 2026 su promedio mensual histórico; dentro del top 10 son Facatativá, Madrid y Fusagasugá. En el total de 350 entidades la cifra es 304, pero ese número está inflado por las entidades pequeñas, para las que el modelo predice valores mayores que sus meses en cero.

Decisión que apoya: la Contraloría debe empezar el Plan de Vigilancia 2027 por las 10 entidades del pronóstico, que suman $1,32 billones previstos para 2026, y dar prioridad a Facatativá, Madrid y Fusagasugá, que además crecerían por encima de su promedio. Los montos deben tomarse como un orden de prioridad y no como cifras exactas. Además, el pronóstico no incluye la Ley de Garantías por las elecciones presidenciales de 2026, que restringe la contratación directa en el primer semestre, por lo que en esos meses se debe revisar con los datos reales del SECOP II.



Ilustración 8. Valor contratado por mes: histórico 2023–2025 y pronóstico 2026 del bosque aleatorio. Fuente: elaboración propia con el notebook modelo_predictivo.ipynb.

6. Despliegue

6.1 Tabla de predicciones

Tabla pred_valor_mensual del data warehouse bi_secop, creada con dw/ddl/05_pred_valor_mensual.sql (el notebook la ejecuta antes de guardar). El mismo script amplía dim_tiempo con los 365 días de 2026, para que el pronóstico se una a la dimensión de tiempo. Tiene 8.400 registros: 4.200 de la prueba de 2025 (con valor real, predicho y error) y 4.200 del pronóstico de 2026 (solo predicho). Se une a dim_entidad por entidad_key y a dim_tiempo por fecha_key.

Columna	Tipo	Descripción
pred_id	BIGINT	Llave primaria (autoincremental)
entidad_key	INT	Llave foránea a dim_entidad
fecha_key	INT	Llave foránea a dim_tiempo (primer día del mes, aaaamm01)
anio, mes	SMALLINT, TINYINT	Año y mes de la predicción
tipo	VARCHAR(20)	«Prueba 2025» o «Pronóstico 2026»
valor_real_millones	DECIMAL(18,2)	Valor real del mes (solo en 2025)
valor_predicho_millones	DECIMAL(18,2)	Predicción del bosque aleatorio
error_abs_millones	DECIMAL(18,2)	Error absoluto (solo en 2025)
promedio_hist_millones	DECIMAL(18,2)	Promedio mensual de la entidad en 2023–2025
modelo, fecha_ejecucion	VARCHAR(60), DATETIME	Algoritmo usado y fecha de la ejecución

6.2 Página de predicciones en el tablero

La página «P4 · Predicciones» del tablero muestra, por mes, el valor real de 2025 junto al valor predicho y el pronóstico de 2026, una tarjeta con el MAE y el top 10 de entidades por valor pronosticado. Se puede filtrar por entidad (dim_entidad) y por tipo de registro (prueba o pronóstico).



Ilustración 9. Página «P4 · Predicciones» del tablero de Power BI. Fuente: elaboración propia.